

CHƯƠNG 3. HỌC MÁY (Machine Learning)

3.1. Khái niệm về học máy


3.2. Các loại học máy

3.3. Các thuật toán học máy

3.4. Ứng dụng của học máy

DỮ LIỆU, THÔNG TIN, TRI THỨC

Thông tin là **dòng** chảy các thông điệp, trong khi tri thức được tạo ra bởi tích lũy thông tin (**kho**)



Hiểu biết đã được kiểm nghiệm, cần cho quyết định và hành động

Chuồn chuồn bay thấp thì mưa

Dữ liệu kèm theo ý nghĩa (do được xử lý)

Chuồn chuồn bay vậy là bay thấp

Tín hiệu quan sát, đo đạc được

0.3m, 0.5m, 0.6m, 0.4m, 0.3m, ... khoảng cách chuồn chuồn bay cách mặt đất.

PHÂN LOẠI DỮ LIỆU



PHÂN LOẠI DỮ LIỆU

Dữ liệu định lượng (Quantitative)

Dữ liệu định lượng là loại dữ liệu có thể được đo lường và biểu diễn thông qua số lượng, bao gồm bất kỳ thông tin nào có thể được đếm hoặc đo lường, cho phép các nhà nghiên cứu thu được kết quả có thể so sánh và tính toán được. Dữ liệu này thường được sử dụng để xác định mối quan hệ, mức độ chênh lệch, hoặc các xu hướng số lượng.

Có hai loại chính của dữ liệu định lượng:

Dữ liệu liên tục: Có thể nhận bất kỳ giá trị nào trong một khoảng. Ví dụ: chiều cao, cân nặng, nhiệt độ, và thời gian.

Dữ liệu rời rạc: Chỉ nhận các giá trị cụ thể, thường là các số đếm. Ví dụ: số lượng sinh viên trong một lớp học, số lần xảy ra một sự kiện.

PHÂN LOẠI DỮ LIỆU

Dữ liệu định tính (Qualitative)

Dữ liệu định tính là loại dữ liệu không thể được đo lường bằng số mà thường được mô tả bằng ngôn từ. Nó chủ yếu dùng để mô tả đặc điểm, thuộc tính, hoặc hiện tượng theo cách không định lượng, tập trung vào "chất" hơn là "lượng". Dữ liệu này thường liên quan đến mô tả về màu sắc, kích thước, hình dạng, cảm xúc, kinh nghiệm và cảm nhận, hoặc bất kỳ khía cạnh nào không thể được tính toán chính xác bằng số.

Họ và tên	Khối	Chiều cao (cm)	Giới tính	Kỹ thuật phát cầu	Số nội dung thi đấu
Trần Văn Long	9	165	Nam	Tốt	3
Nguyễn Trí Tín	8	162	Nam	Khá	2
Lê Thị Thọ	8	168	Nữ	Tốt	2
Nguyễn Thị Thuý	7	160	Nữ	Khá	1
Lý Thành Anh	6	140	Nam	Trung bình	2

PHÂN LOẠI DỮ LIỆU

Ví dụ

- Số lượng cuộc gọi
- Thời gian chờ giao hàng
- Thời gian sản xuất
- Chi phí
- Giá cả
- Nhiệt độ, chiều dài,
- Thời gian (Giờ, Phút và Giây)
- Chiều cao (Feet, Inch, Phân số của inch, v.v.)
- Trọng lượng (Kg, Gram, v.v.)
- Tiền (Đô la, Yên, Euro và các phần nhỏ của chúng)

Để dễ nhớ, có thể hiểu dữ liệu liên tục là những số đếm có giá trị max min.

Dữ liệu liên tục (Continuous data)

DỮ LIỆU ĐỊNH LƯỢNG

- Là dữ liệu dạng định lượng (có thể là số nguyên hoặc số thập phân)
- Dữ liệu được đo bằng dụng cụ đo.
- Có thể đo lường (thang đo hoặc công cụ).
- Chia nhỏ vô tận (về lý thuyết).
- Độ chính xác phụ thuộc vào độ chính xác của thiết bị đo.

PHÂN LOẠI DỮ LIỆU

DỮ LIỆU ĐỊNH LƯỢNG

Ví dụ

- Có bao nhiêu người có thể ngồi thoải mái trong một chiếc máy bay?. Không có nghĩa gì khi nói 129.7632213 người. Nó là 129 hoặc 130, trong trường hợp này bạn sẽ làm tròn xuống 129.
- xếp hạng được cung cấp trên FMEA về Mức độ nghiêm trọng, Sự xuất hiện và Phát hiện
- Màu xanh, đỏ...
- giới tính
- chủng tộc
- số lỗi trên một mẫu đơn đặt hàng hoặc trong một loạt các bộ phận
- đảng phái chính trị (được coi là dữ liệu phân loại rời rạc)
- số lượng sinh viên hoặc công nhân
- số lượng máy
- các loại lỗi trên một mẫu đơn đặt hàng
- số lần giao hàng trễ

Dữ liệu rời rạc (Discrete Data)

- Chỉ rời rạc hoặc hữu hạn số lượng giá trị chỉ đếm được và không đo được.
- Là số nguyên.
- Có thể phân loại thành một phân loại (ví dụ màu)
- Không thể chia nhỏ thành các đơn vị nhỏ hơn

PHÂN LOẠI DỮ LIỆU

Dữ liệu khoảng cách (Interval Data)

- Là thang đo thứ bậc, Có đặc tính số lượng, có khoảng cách đều và liên tục. Bao gồm tất cả các đặc điểm của thang đo thứ tự
- Dữ liệu ở 2 cực của khoảng thể hiện trạng thái đối nghịch nhau

Ví dụ về thang đo khoảng là nhiệt độ độ C vì chênh lệch giữa mỗi giá trị là như nhau.

Sự khác biệt giữa 20 và 30 độ là 10 độ có thể đo được, cũng như sự khác biệt giữa 50 và 40 độ.

1. Hoàn toàn đồng ý 2. đồng ý 3. Không đồng ý 4. Phản đối

- 0 -> 20000 Euro
- 20000 -> 40000 Euro
- 40000 -> 60000 Euro
- 60000 -> 80000 Euro

Ở đây “khoảng cách” giữa các giá trị là 20000 euro

DỮ LIỆU ĐỊNH LƯỢNG

PHÂN LOẠI DỮ LIỆU

DỮ LIỆU ĐỊNH LƯỢNG

Dữ liệu tỷ lệ (Ratio Data)

- Là loại thang đo có đặc tính số lượng. Có đầy đủ đặc tính của dữ liệu khoảng nhưng có thêm tỷ lệ so sánh giữa 2 biến số.

Ví dụ: Nếu mặt số trên cân hiển thị số 0, thì hoàn toàn không có trọng lượng

- Nếu anh X kiếm được 6000 usd/ tháng và anh Y kiếm được 2000 usd/tháng.
Thì anh X kiếm được gấp 3 lần anh Y.

PHÂN LOẠI DỮ LIỆU

DỮ LIỆU ĐỊNH TÍNH

Dữ liệu nhị thức (binomial)

chỉ có 2 đặc điểm

- go / no go
- đạt/không đạt
- Tốt/xấu
- vượt qua thất bại
- bật / tắt
- đúng / sai
- toàn trống rỗng
- nóng lạnh
- nhỏ to
- giấy/nhựa

Dữ liệu định danh (Nominal Data)

- Dữ liệu chỉ sử dụng biến tên thay vì giá trị số. Dùng phân loại đối tượng
- Dữ liệu không có thứ tự

Ví dụ

- Hướng – Bắc, Đông, Tây & Nam
- Màu sắc – Xanh lục, Đỏ, Vàng
- Giới tính: nữ, nam

Dữ liệu thứ bậc (Ordinal Data)

- Dữ liệu định tính với một tập hợp/Thứ tự tự nhiên, sắp xếp tăng dần hoặc giảm dần.
- Dữ liệu không có tiêu chuẩn
- Dữ liệu có thể được đo bằng cả Số và Tên

Ví dụ

Các lớp: F, E, D, C, B, A

Tháng- Tháng 1, Tháng 2,..., Tháng 12

Độ sáng: Sáng, Trung bình & Tối

Học lực: yếu, kém trung bình, khá, giỏi, xuất sắc

PHÂN LOẠI DỮ LIỆU

DỮ LIỆU ĐỊNH LƯỢNG

Liên tục

Rời rạc

Họ và tên	Khối	Chiều cao (cm)	Giới tính	Kĩ thuật phát cầu	Số nội dung thi đấu
Trần Văn Long	9	165	Nam	Tốt	3
Nguyễn Trí Tín	8	162	Nam	Khá	2
Lê Thị Thọ	8	168	Nữ	Tốt	2
Nguyễn Thị Thuý	7	160	Nữ	Khá	1
Lý Thành Anh	6	140	Nam	Trung bình	2

Định danh


Thứ bậc

Định danh

Thứ bậc

DỮ LIỆU ĐỊNH TÍNH

3.1. Khái niệm về học máy



KHÁI NIỆM HỌC MÁY


Học máy hay máy học (tiếng Anh: *machine learning*) là một lĩnh vực của trí tuệ nhân tạo liên quan đến việc nghiên cứu và xây dựng các kỹ thuật cho phép các hệ thống "học" tự động từ dữ liệu để giải quyết những vấn đề cụ thể.

Các thuật toán học máy xây dựng một mô hình dựa trên dữ liệu mẫu, được gọi là dữ liệu huấn luyện, để đưa ra dự đoán hoặc quyết định mà không cần được lập trình chi tiết về việc đưa ra dự đoán hoặc quyết định này.

KHÁI NIỆM HỌC MÁY

Ví dụ như các máy có thể "học" cách phân loại thư điện tử xem có phải thư rác (spam) hay không và tự động xếp thư vào thư mục tương ứng.

Classification in Machine Learning



KHÁI NIỆM HỌC MÁY

Một nhánh của học máy là **học sâu** (deep learning) phát triển rất mạnh mẽ gần đây và có những kết quả vượt trội so với các phương pháp học máy khác.

Học máy có liên quan lớn đến thống kê, vì cả hai lĩnh vực đều nghiên cứu việc phân tích dữ liệu, nhưng khác với thống kê, học máy tập trung vào sự phức tạp của các giải thuật trong việc thực thi tính toán.

MỤC ĐÍCH CỦA HỌC MÁY

Mục đích của học máy (machine learning) là tạo ra các hệ thống có khả năng **tự động học hỏi** và **cải thiện hiệu suất** thông qua việc tiếp nhận và phân tích dữ liệu, mà không cần phải lập trình thủ công các quy tắc cụ thể. Cụ thể, mục đích chính của học máy bao gồm:


1. **Tự động hóa quá trình ra quyết định:** Học máy giúp các hệ thống tự động đưa ra các quyết định dựa trên dữ liệu và các mẫu đã học, thay vì dựa vào các quy tắc được định nghĩa trước. Ví dụ, một hệ thống nhận diện khuôn mặt có thể tự động nhận ra các đặc điểm của một người mà không cần chỉ rõ từng đặc điểm.
2. **Dự đoán và ước lượng:** Một trong những mục tiêu quan trọng của học máy là dự đoán tương lai dựa trên dữ liệu quá khứ. Ví dụ, dự đoán giá cổ phiếu, dự đoán bệnh trong y tế, hoặc dự báo thời tiết đều là những ứng dụng quan trọng của học máy.
3. **Phát hiện mẫu ẩn trong dữ liệu:** Học máy có thể khám phá các mẫu phức tạp trong dữ liệu mà con người có thể không dễ dàng nhận ra. Điều này đặc biệt hữu ích trong các lĩnh vực như khai thác dữ liệu (data mining), nơi cần phân tích lượng dữ liệu lớn và phức tạp để tìm ra những mẫu hoặc thông tin quan trọng.

MỤC ĐÍCH CỦA HỌC MÁY


4. **Tối ưu hóa quy trình:** Học máy có thể được sử dụng để tối ưu hóa các quy trình, từ công nghiệp sản xuất, quản lý chuỗi cung ứng, đến việc phân tích hành vi người dùng để cải thiện trải nghiệm khách hàng.
5. **Cải thiện độ chính xác và hiệu suất của các hệ thống thông minh:** Học máy giúp các hệ thống ngày càng chính xác hơn khi phân tích dữ liệu mới. Ví dụ, các hệ thống AI trong y học có thể cải thiện chẩn đoán bệnh khi tiếp nhận nhiều dữ liệu hơn.
6. **Tăng khả năng thích ứng:** Các hệ thống học máy có thể tự điều chỉnh và cải thiện hiệu suất khi điều kiện hoặc dữ liệu đầu vào thay đổi, làm tăng khả năng thích ứng trong các tình huống khác nhau.
7. **Giải quyết các bài toán phức tạp:** Học máy giúp giải quyết các vấn đề phức tạp, chẳng hạn như xử lý ngôn ngữ tự nhiên (NLP), thị giác máy tính (computer vision), hay trò chơi chiến lược, những vấn đề mà phương pháp truyền thống có thể không giải quyết được.

3.2. Các loại học máy

Supervised Learning (Classification Algorithm)



Unsupervised Learning (Clustering Algorithm)



HỌC CÓ GIÁM SÁT

Học có giám sát (Supervised Learning) là một trong những phương pháp phổ biến nhất trong học máy, nơi hệ thống học từ một tập dữ liệu được gán nhãn trước. Mục tiêu của học có giám sát là học được mối quan hệ giữa đầu vào và đầu ra, để có thể dự đoán kết quả cho các dữ liệu mới.


HỌC CÓ GIÁM SÁT

1. Nguyên tắc hoạt động

- **Dữ liệu huấn luyện (Training Data):** Hệ thống được cung cấp một tập dữ liệu gồm các cặp đầu vào (input) và đầu ra (output) mà đầu ra đã được xác định trước. Mỗi đầu vào thường là một vector chứa nhiều thuộc tính, và đầu ra là giá trị mà hệ thống cần dự đoán.
- **Quá trình học:** Mô hình học có giám sát sẽ phân tích dữ liệu huấn luyện và học cách ánh xạ từ đầu vào sang đầu ra dựa trên các mẫu đã có sẵn. Quá trình này thường yêu cầu tối ưu hóa một hàm mất mát (loss function) để giảm thiểu sai số giữa giá trị dự đoán và giá trị thực tế.
- **Dự đoán (Prediction):** Sau khi quá trình học hoàn thành, hệ thống sẽ sử dụng mô hình đã học để dự đoán đầu ra cho các dữ liệu mới, chưa từng xuất hiện trong tập huấn luyện.

HỌC CÓ GIÁM SÁT


SUPERVISED LEARNING



HỌC CÓ GIÁM SÁT

SUPERVISED LEARNING


Supervised machine learning is a branch of artificial intelligence that focuses on training models to make predictions or decisions based on labeled training data.




HỌC CÓ GIÁM SÁT

2. Các loại bài toán trong học có giám sát

- **Phân loại (Classification):** Là bài toán mà đầu ra cần dự đoán thuộc về một trong nhiều lớp (categories). Ví dụ: phân loại email thành "thư rác" hoặc "không phải thư rác" hoặc phân loại ảnh thành các đối tượng khác nhau (chó, mèo, xe cộ,...).
- **Hồi quy (Regression):** Trong bài toán hồi quy, đầu ra cần dự đoán là một giá trị liên tục, ví dụ như dự đoán giá nhà dựa trên diện tích và vị trí, hoặc dự đoán nhiệt độ trong ngày.



Hình: Phân loại nhị phân và phân loại đa hình



Hình: Hồi quy ngày so với lượng mưa (tính bằng mm)

HỌC CÓ GIÁM SÁT

So sánh giữa Clasification(Phân loại) và Regression(Quy hồi):

THÔNG SỐ	PHÂN LOẠI	HỒI QUY
Căn bản	Chức năng ánh xạ cơ bản được sử dụng để ánh xạ các giá trị đến các lớp được xác định trước.	Hàm ánh xạ được sử dụng để ánh xạ các giá trị tới đầu ra liên tục.
Liên quan đến dự đoán	Các giá trị Rời rạc	Giá trị liên tục
Bản chất của dữ liệu dự đoán	không theo thứ tự	Có thứ tự
Phương pháp tính toán	bằng cách đo độ chính xác	bằng phép đo sai số trung bình bậc hai
Thuật toán Ví dụ	Ví dụ Cây quyết định, hồi quy logistic, v.v.	Cây hồi quy (Rừng ngẫu nhiên), Hồi quy tuyến tính, v.v.

HỌC CÓ GIÁM SÁT

3. Quá trình huấn luyện và kiểm thử

- **Huấn luyện mô hình (Training the Model):** Tập dữ liệu huấn luyện được sử dụng để xây dựng mô hình. Trong quá trình huấn luyện, mô hình cố gắng học cách dự đoán đầu ra cho các đầu vào mới dựa trên các mẫu đã học.
- **Kiểm thử mô hình (Testing the Model):** Sau khi mô hình đã học xong, nó sẽ được kiểm tra trên một tập dữ liệu kiểm thử chưa từng thấy trước đó để đánh giá hiệu suất và tính chính xác của mô hình.

HỌC CÓ GIÁM SÁT

3. Quá trình huấn luyện và kiểm thử

- **Huấn luyện mô hình (Training the Model):** Tập dữ liệu huấn luyện được sử dụng để xây dựng mô hình. Trong quá trình huấn luyện, mô hình cố gắng học cách dự đoán đầu ra cho các đầu vào mới dựa trên các mẫu đã học.
- **Kiểm thử mô hình (Testing the Model):** Sau khi mô hình đã học xong, nó sẽ được kiểm tra trên một tập dữ liệu kiểm thử chưa từng thấy trước đó để đánh giá hiệu suất và tính chính xác của mô hình.

4. Ví dụ về học có giám sát

- **Phân loại email thành thư rác hoặc không phải thư rác:** Tập dữ liệu huấn luyện bao gồm nhiều email, mỗi email đã được gán nhãn là "thư rác" hoặc "không phải thư rác". Hệ thống học cách phân biệt dựa trên nội dung, người gửi, và các thuộc tính khác.
- **Dự đoán giá nhà:** Tập dữ liệu huấn luyện bao gồm nhiều ngôi nhà với các thuộc tính như diện tích, vị trí, số phòng, và giá bán. Hệ thống học cách dự đoán giá nhà mới dựa trên các thuộc tính tương tự.

HỌC CÓ GIÁM SÁT

5. Ưu điểm và nhược điểm của học có giám sát

- **Ưu điểm:**
 - **Chính xác:** Nếu có đủ dữ liệu và mô hình được huấn luyện tốt, kết quả dự đoán sẽ rất chính xác.
 - **Dễ triển khai:** Các phương pháp học có giám sát đã được phát triển đầy đủ và có nhiều thư viện hỗ trợ.
- **Nhược điểm:**
 - **Cần nhiều dữ liệu gán nhãn:** Để có được mô hình chất lượng cao, cần phải có một lượng lớn dữ liệu đã được gán nhãn, và việc này có thể tốn kém và mất thời gian.
 - **Quá phụ thuộc vào dữ liệu:** Nếu dữ liệu huấn luyện có chứa lỗi hoặc không đại diện cho toàn bộ tập dữ liệu, mô hình có thể không hoạt động tốt trên dữ liệu mới.

HỌC CÓ GIÁM SÁT

6. Các thuật toán phổ biến trong học có giám sát

- Hồi quy tuyến tính (Linear Regression): Sử dụng trong bài toán hồi quy để dự đoán giá trị liên tục.
- Cây quyết định (Decision Trees): Sử dụng trong cả bài toán phân loại và hồi quy.
- K-Nearest Neighbors (KNN): Thuật toán phân loại dựa trên khoảng cách giữa các điểm dữ liệu.
- SVM (Support Vector Machines): Sử dụng cho bài toán phân loại với mục tiêu tìm biên quyết định tối ưu.
- Mạng nơ-ron nhân tạo (Artificial Neural Networks): Mô hình học sâu phổ biến để giải quyết cả phân loại và hồi quy với dữ liệu phức tạp.

7. Ứng dụng thực tế của học có giám sát

- Nhận dạng chữ viết tay: Xác định các ký tự hoặc từ trong hình ảnh văn bản.
- Phân loại bệnh trong y tế: Phân tích các dấu hiệu từ dữ liệu y tế để phân loại bệnh nhân.
- Dự báo tài chính: Dự đoán giá cổ phiếu hoặc doanh thu của một công ty dựa trên các yếu tố kinh tế.

HỌC KHÔNG GIÁM SÁT

Học không giám sát (Unsupervised Learning) là một phương pháp học máy trong đó hệ thống học từ dữ liệu **không có nhãn**. Điều này có nghĩa là không có giá trị đầu ra xác định trước hoặc thông tin hướng dẫn cụ thể nào cho hệ thống về cách dữ liệu cần được xử lý. Thay vì dự đoán giá trị hay phân loại, mục tiêu của học không giám sát là tìm kiếm các cấu trúc hoặc mẫu tiềm ẩn trong dữ liệu.


HỌC KHÔNG GIÁM SÁT

1. Nguyên tắc hoạt động

Trong học không giám sát, hệ thống được cung cấp một tập dữ liệu đầu vào mà không có bất kỳ nhãn hay giá trị đầu ra nào. Nhiệm vụ của hệ thống là phân tích và tìm ra các mẫu hoặc cấu trúc trong dữ liệu đó. Điều này có thể bao gồm việc phát hiện các cụm (clusters) của dữ liệu, giảm số chiều (dimension) của dữ liệu, hoặc tìm kiếm các mối liên hệ giữa các đặc điểm của dữ liệu.

HỌC KHÔNG GIÁM SÁT


UNSUPERVISED LEARNING



HỌC KHÔNG GIÁM SÁT

UNSUPERVISED LEARNING

Unsupervised learning is a type of machine learning where the algorithm learns from unlabeled data without any predefined outputs or target variables.



HỌC KHÔNG GIÁM SÁT

2. Các bài toán phổ biến trong học không giám sát

- **Phân cụm (Clustering):** Phân cụm là bài toán chính trong học không giám sát. Hệ thống phân chia các mẫu dữ liệu thành các nhóm khác nhau sao cho các mẫu trong cùng một nhóm có tính chất tương đồng với nhau hơn so với các mẫu trong nhóm khác.
 - **Ví dụ:** Phân loại khách hàng thành các nhóm dựa trên hành vi mua sắm, phân cụm các bài viết thành các chủ đề khác nhau.
- **Giảm số chiều (Dimensionality Reduction):** Giảm số chiều là kỹ thuật giúp giảm số lượng các đặc điểm trong dữ liệu mà vẫn bảo toàn được thông tin quan trọng. Điều này giúp đơn giản hóa mô hình và giảm độ phức tạp của tính toán.
 - **Ví dụ:** Principal Component Analysis (PCA) là một kỹ thuật phổ biến để giảm số chiều trong dữ liệu hình ảnh hoặc dữ liệu lớn có nhiều biến số.
- **Phát hiện bất thường (Anomaly Detection):** Phát hiện bất thường là việc xác định các mẫu dữ liệu có tính chất không bình thường hoặc khác biệt so với phần còn lại của dữ liệu.
 - **Ví dụ:** Phát hiện giao dịch gian lận trong thẻ tín dụng hoặc phát hiện lỗi trong hệ thống sản xuất.

HỌC KHÔNG GIÁM SÁT

3. Các thuật toán phổ biến trong học không giám sát

- **Phân cụm K-means (K-means Clustering):** K-means là thuật toán phân cụm phổ biến nhất trong học không giám sát. Nó tìm cách chia dữ liệu thành K nhóm (cụm) dựa trên tính tương đồng giữa các điểm dữ liệu. Mỗi cụm được biểu diễn bởi một "trung tâm" (centroid), và các điểm dữ liệu được gán vào cụm có trung tâm gần nhất.
 - **Ứng dụng:** Phân loại khách hàng, phân tích hành vi người dùng.
- **Phân tích thành phần chính (Principal Component Analysis - PCA):** PCA là kỹ thuật giảm số chiều, giúp tìm ra các thành phần chính đại diện cho dữ liệu một cách hiệu quả nhất. PCA được sử dụng khi dữ liệu có quá nhiều biến số và cần phải giảm bớt để đơn giản hóa mà vẫn bảo toàn thông tin quan trọng.
 - **Ứng dụng:** Giảm số chiều trong dữ liệu hình ảnh, phân tích dữ liệu kinh tế.

HỌC KHÔNG GIÁM SÁT

- **Hierarchical Clustering (Phân cụm phân cấp):** Phân cụm phân cấp tạo ra một "cây phân cấp" của các nhóm, từ mức phân chia nhỏ nhất (từng điểm dữ liệu riêng lẻ) cho đến mức phân cụm toàn bộ dữ liệu thành một cụm duy nhất. Điều này giúp hiểu rõ cấu trúc phân cấp giữa các nhóm trong dữ liệu.
 - **Ứng dụng:** Phân tích phân cấp trong các tổ chức hoặc hệ thống.
- **Hệ thống gán nhãn tự động (Autoencoders):** Autoencoder là một loại mạng nơ-ron học không giám sát có mục tiêu học cách nén dữ liệu đầu vào thành một không gian đặc trưng (latent space) có số chiều thấp hơn, sau đó tái tạo lại dữ liệu từ không gian này. Kỹ thuật này thường được sử dụng trong giảm số chiều và phát hiện bất thường.
 - **Ứng dụng:** Phát hiện bất thường, nén dữ liệu, học biểu diễn trong học sâu.

HỌC KHÔNG GIÁM SÁT

4. Ví dụ ứng dụng của học không giám sát

- **Phân tích khách hàng:** Trong thương mại điện tử, học không giám sát được sử dụng để phân cụm khách hàng thành các nhóm dựa trên hành vi mua sắm, độ tuổi, hoặc khu vực. Điều này giúp các công ty hiểu rõ hơn về khách hàng của họ và tùy chỉnh chiến lược tiếp thị.
- **Phát hiện bất thường trong y tế:** Học không giám sát có thể được sử dụng để phát hiện các mẫu bệnh lý không bình thường trong dữ liệu y tế, chẳng hạn như phát hiện sớm các triệu chứng hiếm gặp hoặc phát hiện khối u bất thường trong ảnh y khoa.
- **Xử lý ngôn ngữ tự nhiên (NLP):** Trong xử lý ngôn ngữ tự nhiên, học không giám sát được sử dụng để phân cụm tài liệu văn bản, phát hiện các chủ đề hoặc biểu diễn các từ dưới dạng vector (Word Embeddings), giúp cải thiện các bài toán như dịch thuật tự động và tìm kiếm ngữ nghĩa.

HỌC KHÔNG GIÁM SÁT

5. Ưu điểm và nhược điểm của học không giám sát

- **Ưu điểm:**
 - **Không cần gán nhãn dữ liệu:** Học không giám sát không yêu cầu dữ liệu phải được gán nhãn, giúp giảm đáng kể chi phí và thời gian chuẩn bị dữ liệu.
 - **Khám phá cấu trúc ẩn:** Học không giám sát có khả năng tìm ra các cấu trúc hoặc mẫu ẩn mà có thể không rõ ràng với con người.
- **Nhược điểm:**
 - **Khó đánh giá hiệu suất:** Vì không có nhãn để so sánh, việc đánh giá độ chính xác của mô hình trong học không giám sát khó khăn hơn.
 - **Không đảm bảo tìm ra được cấu trúc hữu ích:** Một số thuật toán học không giám sát có thể phát hiện ra các mẫu hoặc cụm dữ liệu mà không có ý nghĩa thực tế.

HỌC KHÔNG GIÁM SÁT

6. Khi nào nên sử dụng học không giám sát

- **Dữ liệu chưa được gán nhãn:** Khi bạn có một lượng lớn dữ liệu nhưng không có nhãn cụ thể, học không giám sát là phương pháp tối ưu để khám phá các mẫu và cấu trúc trong dữ liệu đó.
- **Khám phá kiến thức tiềm ẩn:** Học không giám sát giúp khám phá các quan hệ hoặc cấu trúc ẩn trong dữ liệu mà con người không dễ dàng nhận ra. Điều này hữu ích trong phân tích dữ liệu để tìm hiểu sâu hơn về các yếu tố tác động.
- **Tăng cường hiểu biết về dữ liệu:** Trước khi áp dụng các mô hình học có giám sát, học không giám sát có thể giúp bạn hiểu rõ hơn về dữ liệu của mình, tìm ra các cụm hoặc nhóm tiềm năng, và sau đó sử dụng thông tin này để tối ưu hóa quá trình học có giám sát.

HỌC BÁN GIÁM SÁT

Học bán giám sát (Semi-supervised Learning) là một phương pháp học máy kết hợp cả học có giám sát và học không giám sát. Phương pháp này sử dụng một lượng nhỏ dữ liệu có gán nhãn và một lượng lớn dữ liệu không gán nhãn để huấn luyện mô hình. Mục tiêu của học bán giám sát là cải thiện độ chính xác của mô hình học có giám sát bằng cách tận dụng dữ liệu không gán nhãn để hỗ trợ quá trình học.

HỌC BÁN GIÁM SÁT

1. Nguyên tắc hoạt động

Trong học bán giám sát, hệ thống học từ một tập dữ liệu mà chỉ có một phần nhỏ là được gán nhãn (supervised), phần còn lại không có nhãn (unsupervised). Phần dữ liệu không gán nhãn được sử dụng để giúp hệ thống học các cấu trúc tiềm ẩn trong dữ liệu, sau đó hỗ trợ việc gán nhãn cho các mẫu dữ liệu mới hoặc cải thiện quá trình phân loại/ dự đoán dựa trên phần dữ liệu đã gán nhãn.

Quá trình học thường diễn ra theo hai giai đoạn:

- **Học từ dữ liệu có gán nhãn:** Hệ thống trước tiên học từ các mẫu dữ liệu đã được gán nhãn (có đầu vào và đầu ra), tương tự như trong học có giám sát.
- **Học từ dữ liệu không gán nhãn:** Sau đó, mô hình sẽ sử dụng các mẫu dữ liệu không có nhãn để tìm hiểu thêm về cấu trúc của dữ liệu, từ đó tăng cường hiệu suất cho mô hình.

HỌC BÁN GIÁM SÁT



HỌC BÁN GIÁM SÁT

2. Lý do sử dụng học bán giám sát

- **Giảm chi phí gán nhãn:** Quá trình gán nhãn cho dữ liệu, đặc biệt là trong các lĩnh vực phức tạp như y học, hình ảnh, hoặc ngôn ngữ, thường tốn kém và mất nhiều thời gian. Học bán giám sát giúp giảm bớt sự phụ thuộc vào dữ liệu gán nhãn, chỉ cần một lượng nhỏ dữ liệu đã gán nhãn để khởi tạo mô hình.
- **Tận dụng dữ liệu không gán nhãn:** Dữ liệu không gán nhãn thường có sẵn với số lượng lớn trong nhiều lĩnh vực, như dữ liệu hình ảnh trên mạng xã hội, dữ liệu văn bản từ các trang web, hoặc dữ liệu tín hiệu cảm biến. Sử dụng học bán giám sát giúp khai thác hiệu quả nguồn dữ liệu này.

HỌC BÁN GIÁM SÁT

3. Các bài toán trong học bán giám sát

Học bán giám sát thường được áp dụng trong các bài toán sau:

- **Phân loại (Classification):** Bài toán phân loại là một trong những ứng dụng phổ biến nhất của học bán giám sát. Hệ thống học cách phân loại dữ liệu với một lượng nhỏ mẫu đã gán nhãn và dùng dữ liệu không gán nhãn để hỗ trợ cải thiện độ chính xác của mô hình.
 - **Ví dụ:** Phân loại email thành thư rác hoặc không phải thư rác, phân loại hình ảnh thành các danh mục khác nhau.
- **Hồi quy (Regression):** Hệ thống có thể sử dụng một lượng nhỏ dữ liệu có gán nhãn để dự đoán giá trị liên tục cho các dữ liệu mới chưa gán nhãn.
 - **Ví dụ:** Dự đoán giá cổ phiếu hoặc dự đoán giá nhà với số lượng dữ liệu có gán nhãn hạn chế.

HỌC BÁN GIÁM SÁT

4. Các thuật toán phổ biến trong học bán giám sát

- **Self-training (Tự huấn luyện):** Đây là một phương pháp đơn giản trong đó mô hình học có giám sát được huấn luyện trước tiên trên dữ liệu có gán nhãn. Sau đó, mô hình sẽ được sử dụng để dự đoán nhãn cho dữ liệu không gán nhãn. Các nhãn dự đoán này sau đó được thêm vào dữ liệu gán nhãn để tiếp tục cải thiện mô hình.
- **Co-training (Đồng huấn luyện):** Phương pháp này yêu cầu hai mô hình học khác nhau được huấn luyện trên các tập con dữ liệu khác nhau. Mỗi mô hình sẽ dự đoán nhãn cho dữ liệu không gán nhãn và các nhãn đó sẽ được dùng để huấn luyện mô hình còn lại.
- **Graph-based Methods (Phương pháp dựa trên đồ thị):** Trong phương pháp này, dữ liệu được biểu diễn dưới dạng đồ thị, trong đó mỗi điểm dữ liệu là một nút và cạnh biểu thị sự tương đồng giữa các điểm dữ liệu. Các nhãn từ dữ liệu có gán nhãn sẽ lan truyền qua đồ thị để gán nhãn cho các điểm dữ liệu chưa được gán nhãn.
- **Generative Models (Mô hình sinh):** Mô hình sinh tạo ra một phân phối xác suất cho cả dữ liệu có gán nhãn và không gán nhãn, và sử dụng phân phối này để cải thiện quá trình dự đoán.

HỌC BÁN GIÁM SÁT

5. Ví dụ ứng dụng của học bán giám sát

- **Nhận dạng hình ảnh:** Trong thị giác máy tính, gán nhãn dữ liệu hình ảnh thường tốn nhiều công sức và chi phí. Học bán giám sát giúp sử dụng một lượng nhỏ ảnh đã gán nhãn và tận dụng hàng triệu ảnh không gán nhãn để huấn luyện mô hình nhận dạng hình ảnh, như nhận diện khuôn mặt hoặc phân loại vật thể.
- **Xử lý ngôn ngữ tự nhiên (NLP):** Trong các bài toán như dịch thuật tự động hoặc phân loại văn bản, học bán giám sát được sử dụng để tận dụng các tập văn bản không có nhãn nhằm cải thiện chất lượng dự đoán.
- **Phân loại bệnh trong y tế:** Trong lĩnh vực y học, việc gán nhãn dữ liệu bệnh nhân thường đòi hỏi các chuyên gia và mất nhiều thời gian. Học bán giám sát có thể được sử dụng để phân loại các hình ảnh y tế hoặc phát hiện bệnh bằng cách sử dụng một lượng nhỏ dữ liệu có gán nhãn từ các bác sĩ và một lượng lớn dữ liệu không gán nhãn.

HỌC BÁN GIÁM SÁT

6. Ưu điểm và nhược điểm của học bán giám sát

- **Ưu điểm:**
 - **Giảm chi phí gán nhãn:** Phương pháp này giúp giảm nhu cầu về dữ liệu đã gán nhãn, từ đó tiết kiệm thời gian và chi phí.
 - **Tận dụng dữ liệu không gán nhãn:** Khả năng tận dụng nguồn dữ liệu không gán nhãn giúp tăng cường khả năng học của hệ thống mà không cần mở rộng tập dữ liệu gán nhãn.
- **Nhược điểm:**
 - **Cần dữ liệu không gán nhãn chất lượng:** Nếu dữ liệu không gán nhãn không đại diện cho toàn bộ tập dữ liệu hoặc chứa nhiều nhiễu, mô hình có thể học sai.
 - **Khó triển khai:** Một số thuật toán học bán giám sát phức tạp hơn trong triển khai so với học có giám sát, đòi hỏi cấu trúc dữ liệu phù hợp.

HỌC BÁN GIÁM SÁT

7. Khi nào nên sử dụng học bán giám sát

- **Khi dữ liệu gán nhãn khó thu thập:** Học bán giám sát là giải pháp tốt khi việc gán nhãn dữ liệu tốn nhiều thời gian hoặc đòi hỏi kiến thức chuyên gia.
- **Khi có sẵn nhiều dữ liệu không gán nhãn:** Nếu bạn có nhiều dữ liệu không gán nhãn, học bán giám sát là cách tận dụng chúng để cải thiện chất lượng của mô hình học có giám sát.
- **Bài toán cần sự chính xác cao:** Học bán giám sát thường được áp dụng khi bạn muốn đạt được độ chính xác cao mà không thể chỉ dựa vào dữ liệu gán nhãn hạn chế.

HỌC TĂNG CƯỜNG

Học tăng cường (Reinforcement Learning - RL) là một phương pháp học máy mà trong đó một tác nhân (agent) học cách đưa ra các quyết định tối ưu bằng cách tương tác với môi trường xung quanh. Thay vì học từ một tập dữ liệu có sẵn, tác nhân học thông qua việc thử nghiệm và nhận phản hồi từ môi trường dưới dạng phần thưởng hoặc hình phạt. Mục tiêu của học tăng cường là tối ưu hóa chiến lược hành động của tác nhân để nhận được nhiều phần thưởng nhất có thể theo thời gian.


HỌC TĂNG CƯỜNG

1. Nguyên tắc hoạt động

Trong học tăng cường, hệ thống bao gồm một số thành phần chính:

- **Tác nhân (Agent):** Là hệ thống hoặc mô hình học máy, có nhiệm vụ thực hiện các hành động trong môi trường để đạt được mục tiêu.
- **Môi trường (Environment):** Là thế giới xung quanh mà tác nhân tương tác. Môi trường phản hồi lại tác nhân thông qua các trạng thái và phần thưởng.
- **Trạng thái (State):** Tác nhân quan sát trạng thái hiện tại của môi trường. Trạng thái có thể thay đổi dựa trên hành động của tác nhân.
- **Hành động (Action):** Tác nhân có thể thực hiện một số hành động từ một tập hợp các hành động có thể có tại một thời điểm. Mỗi hành động sẽ dẫn đến thay đổi trạng thái của môi trường.
- **Phần thưởng (Reward):** Sau khi tác nhân thực hiện một hành động, môi trường phản hồi bằng cách cung cấp một phần thưởng (thường là số dương, số âm, hoặc không có giá trị), phản ánh mức độ tốt hay xấu của hành động đó.
- **Chính sách (Policy):** Là chiến lược mà tác nhân sử dụng để chọn hành động dựa trên trạng thái hiện tại. Mục tiêu của tác nhân là tìm ra chính sách tối ưu để nhận được tổng phần thưởng cao nhất trong dài hạn.

Reinforcement Learning



HỌC TĂNG CƯỜNG

2. Bài toán học tăng cường

Bài toán học tăng cường thường được biểu diễn bằng **Mô hình quyết định Markov** (Markov Decision Process - MDP), gồm các thành phần sau:

- **S**: Tập hợp các trạng thái (States).
- **A**: Tập hợp các hành động (Actions).
- **$P(s'|s, a)$** : Xác suất chuyển đổi từ trạng thái s sang trạng thái s' khi thực hiện hành động a .
- **$R(s, a)$** : Phần thưởng mà tác nhân nhận được khi thực hiện hành động a tại trạng thái s .
- **γ (gamma)**: Hệ số chiết khấu (Discount Factor), xác định tầm quan trọng của phần thưởng trong tương lai so với phần thưởng hiện tại.

Mục tiêu của bài toán là tìm ra chính sách tối ưu (π^*) để tối đa hóa tổng phần thưởng dự kiến (expected cumulative reward), được gọi là **giá trị kỳ vọng**.

HỌC TĂNG CƯỜNG

3. Các thuật toán phổ biến trong học tăng cường

- **Q-learning:** Đây là một trong những thuật toán học tăng cường phổ biến nhất. Q-learning là một phương pháp dựa trên bảng (table-based) để tìm ra chính sách tối ưu bằng cách ước tính giá trị Q cho mỗi cặp trạng thái và hành động. Giá trị $Q(s, a)$ thể hiện "giá trị" của việc thực hiện hành động a tại trạng thái s . Tác nhân liên tục cập nhật bảng Q bằng cách sử dụng phương trình Q-learning:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left(R(s, a) + \gamma \max_{a'} Q(s', a') - Q(s, a) \right)$$

- **Ứng dụng:** Q-learning được sử dụng rộng rãi trong các bài toán như tối ưu hóa đường đi, điều khiển robot, chơi trò chơi.
- **Deep Q-Network (DQN):** Là một phiên bản mở rộng của Q-learning, sử dụng mạng nơ-ron sâu (deep neural networks) để xấp xỉ giá trị Q, đặc biệt hữu ích khi không gian trạng thái quá lớn hoặc liên tục. DQN đã được sử dụng thành công trong các trò chơi phức tạp như trò chơi Atari và các hệ thống điều khiển.

HỌC TĂNG CƯỜNG

- **Policy Gradient:** Thay vì ước tính giá trị Q cho mỗi trạng thái và hành động, thuật toán Policy Gradient trực tiếp tối ưu hóa chính sách hành động. Chính sách được biểu diễn dưới dạng một hàm xác suất, và mục tiêu là tìm ra các tham số tối ưu cho hàm này để tối đa hóa phần thưởng dự kiến.
 - **REINFORCE** là một thuật toán phổ biến trong Policy Gradient, trong đó tác nhân sẽ điều chỉnh các tham số của chính sách dựa trên phần thưởng nhận được từ môi trường.
- **Actor-Critic:** Là sự kết hợp giữa Q-learning và Policy Gradient. Actor-Critic sử dụng hai mô hình riêng biệt: "actor" để chọn hành động và "critic" để ước tính giá trị của trạng thái. Actor quyết định hành động nào nên thực hiện, trong khi Critic đánh giá hành động đó tốt hay xấu và cung cấp phản hồi để điều chỉnh chiến lược của Actor.

HỌC TĂNG CƯỜNG

4. Ví dụ ứng dụng của học tăng cường

- **AI chơi game:** Học tăng cường đã đạt được những bước tiến lớn trong việc huấn luyện các tác nhân thông minh để chơi các trò chơi như cờ vua, cờ vây, và trò chơi điện tử. Đặc biệt, AlphaGo của Google DeepMind đã sử dụng học tăng cường để đánh bại nhà vô địch thế giới trong trò chơi cờ vây.
- **Robot tự hành:** Học tăng cường được sử dụng trong điều khiển robot để giúp chúng học cách di chuyển, tránh chướng ngại vật, hoặc tương tác với môi trường mà không cần lập trình trước.
- **Hệ thống đề xuất:** Học tăng cường có thể được sử dụng để tối ưu hóa các hệ thống gợi ý như gợi ý sản phẩm hoặc nội dung cho người dùng dựa trên hành vi tương tác.
- **Điều khiển hệ thống:** Học tăng cường được áp dụng trong các hệ thống điều khiển tự động như điều khiển nhiệt độ trong các tòa nhà, tối ưu hóa hiệu suất trong hệ thống sản xuất hoặc quản lý năng lượng.

HỌC TĂNG CƯỜNG

5. Ưu điểm và nhược điểm của học tăng cường


- **Ưu điểm:**
 - **Học từ phản hồi động:** Học tăng cường cho phép tác nhân học từ môi trường phức tạp và phản hồi liên tục, không cần tập dữ liệu huấn luyện cố định.
 - **Áp dụng được cho các bài toán phức tạp:** Học tăng cường có khả năng xử lý các bài toán có nhiều tương tác, thay đổi theo thời gian và không thể lập trình trước chính xác.
- **Nhược điểm:**
 - **Yêu cầu tính toán lớn:** Học tăng cường thường cần nhiều tài nguyên tính toán, đặc biệt khi môi trường phức tạp và không gian trạng thái lớn.
 - **Quá trình học không ổn định:** Tác nhân có thể mất nhiều thời gian để học, và quá trình học có thể không ổn định, đặc biệt nếu có sự thay đổi lớn trong môi trường.

HỌC TĂNG CƯỜNG

6. Khi nào nên sử dụng học tăng cường

- **Bài toán có sự tương tác liên tục với môi trường:** Học tăng cường được áp dụng khi tác nhân cần học cách tương tác và ra quyết định trong môi trường mà các hành động của nó ảnh hưởng đến trạng thái và phản hồi từ môi trường.
- **Không có dữ liệu huấn luyện cố định:** Học tăng cường hữu ích trong các tình huống mà không có sẵn tập dữ liệu có nhãn cố định, và mô hình cần tự học qua thử nghiệm và sai lầm.
- **Tối ưu hóa dài hạn:** Khi cần tối ưu hóa lợi ích dài hạn thay vì chỉ tối ưu hóa trong ngắn hạn, học tăng cường sẽ là một lựa chọn phù hợp.

3.3. Các thuật toán học máy



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

1. Hồi quy tuyến tính (Linear Regression)


Cách hoạt động:

Hồi quy tuyến tính được sử dụng để dự đoán giá trị liên tục của biến mục tiêu dựa trên một hoặc nhiều biến độc lập. Mô hình tìm cách xây dựng một đường thẳng (trong trường hợp đơn biến) hoặc một siêu phẳng (trong trường hợp đa biến) mà tối ưu hóa việc dự đoán giá trị đầu ra bằng cách giảm thiểu tổng bình phương sai số (Least Squares).

Phương trình hồi quy tuyến tính đơn biến:

$$y = wx + b$$

- **y**: Biến phụ thuộc (giá trị cần dự đoán)
- **x**: Biến độc lập (đầu vào)
- **w**: Hệ số góc (trọng số)
- **b**: Hệ số chặn (intercept)



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ưu điểm:


- Đơn giản và dễ hiểu: Dễ dàng triển khai và giải thích kết quả.
- Hiệu quả với dữ liệu **tuyến tính**: Hoạt động tốt khi mối quan hệ giữa các biến là tuyến tính.
- Tính toán nhanh: Yêu cầu ít tài nguyên tính toán.

Nhược điểm:


- Giới hạn với quan hệ **phi tuyến**: Không phù hợp nếu mối quan hệ giữa biến độc lập và phụ thuộc là phi tuyến.
- Nhạy cảm với nhiễu: Các giá trị ngoại lai có thể ảnh hưởng lớn đến mô hình.
- Giả định về phân phối dữ liệu: Giả định rằng dữ liệu phải tuân theo phân phối chuẩn và các biến độc lập không tương quan.

Ví dụ:

- Dự đoán giá nhà: Sử dụng diện tích, số phòng, vị trí để dự đoán giá bán của một ngôi nhà.
- Dự đoán doanh số bán hàng: Dựa vào chi phí quảng cáo để dự đoán doanh số bán hàng.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn import metrics

# Tạo dữ liệu mẫu
X = np.array([[1], [2], [3], [4], [5]])
y = np.array([1, 3, 2, 3, 5])

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)


# Tạo mô hình hồi quy tuyến tính
regressor = LinearRegression()

# Huấn luyện mô hình
regressor.fit(X_train, y_train)

# Dự đoán trên tập kiểm tra
y_pred = regressor.predict(X_test)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán giá nhà dựa trên diện tích



Tập Train	
Diện tích (m2)	Giá nhà (k\$)
30	150
50	200
70	250
80	300
100	400

Tập Test	
Diện tích (m2)	Giá nhà (k\$)
60	?
90	?

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

2. Hồi quy logistic (Logistic Regression)


Cách hoạt động:

Hồi quy logistic được sử dụng cho các bài toán phân loại nhị phân (có hai lớp). Mô hình ước tính xác suất của một mẫu dữ liệu thuộc về một lớp cụ thể bằng cách sử dụng hàm logistic (hàm sigmoid).

Phương trình hồi quy logistic:

$$P(y = 1|x) = \frac{1}{1 + e^{-(wx+b)}}$$

- $P(y=1|x)$: Xác suất mẫu thuộc lớp 1.
- $w x + b$: Tổng trọng số của các biến độc lập.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ưu điểm:


- **Giải thích rõ ràng:** Hệ số của mô hình cho biết mức độ ảnh hưởng của từng biến.
- **Hiệu quả với phân loại nhị phân:** Tốt cho các bài toán phân loại có hai lớp.
- **Khả năng dự đoán xác suất:** Cung cấp xác suất thuộc về một lớp, hữu ích trong nhiều ứng dụng.

Nhược điểm:


- **Không phù hợp với phân loại đa lớp:** Cần mở rộng thành hồi quy logistic đa thức (Multinomial Logistic Regression) cho bài toán nhiều lớp.
- **Giả định tuyến tính giữa biến độc lập và logit của xác suất:** Có thể không phù hợp nếu quan hệ phi tuyến.
- **Nhạy cảm với đa cộng tuyến:** Khi các biến độc lập tương quan cao, mô hình có thể không ổn định.

Ví dụ:

- **Dự đoán khả năng mắc bệnh:** Dựa trên các chỉ số y tế để dự đoán liệu một bệnh nhân có mắc bệnh hay không.
- **Phân loại email:** Xác định email là "thư rác" hay "không phải thư rác".



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

```
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn import metrics

# Tạo dữ liệu mẫu
X = np.array([[1], [2], [3], [4], [5], [6], [7], [8], [9], [10]])
y = np.array([0, 0, 0, 0, 1, 1, 1, 1, 1, 1])


# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=0)

# Tạo mô hình hồi quy logistic
logreg = LogisticRegression()

# Huấn luyện mô hình
logreg.fit(X_train, y_train)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán kết quả thi dựa vào số giờ học



Tập Train	
Giờ học	Kết quả
3	0
5	0
7	1
8	1
4	0
7	1
8	1
9	1
6	1

Tập Test	
Giờ học	Kết quả
4	?
7	?

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


3. Cây quyết định (Decision Trees)

Cách hoạt động:

Cây quyết định là một mô hình phân loại và hồi quy sử dụng cấu trúc cây để đưa ra quyết định dựa trên các điều kiện trên biến độc lập. Mỗi nút trong cây đại diện cho một thuộc tính, các nhánh biểu thị kết quả của kiểm tra thuộc tính, và các lá thể hiện quyết định cuối cùng hoặc giá trị dự đoán.

Ví dụ:

- **Phân loại khách hàng:** Dựa trên hành vi mua sắm để phân loại khách hàng thành các nhóm khác nhau.
- **Chẩn đoán bệnh:** Sử dụng các triệu chứng để xác định bệnh mà bệnh nhân có thể mắc phải.




CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ưu điểm:


- Dễ hiểu và giải thích: Cấu trúc cây trực quan, dễ dàng giải thích kết quả.
- Xử lý dữ liệu phi tuyến: Có thể mô hình hóa mối quan hệ phi tuyến giữa các biến.
- Ít yêu cầu về tiền xử lý dữ liệu: Không cần chuẩn hóa hoặc tiêu chuẩn hóa dữ liệu.

Nhược điểm:

- Quá khớp (Overfitting): Cây quyết định có thể quá khớp với dữ liệu huấn luyện nếu không được tỉa (pruned) đúng cách.
- Không ổn định: Thay đổi nhỏ trong dữ liệu có thể dẫn đến thay đổi lớn trong cấu trúc cây.
- Thiên vị với thuộc tính có nhiều cấp: Các thuộc tính với nhiều giá trị có thể chi phối quá trình xây dựng cây.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

```
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import train_test_split
from sklearn import metrics

# Tải dữ liệu mẫu
iris = load_iris()
X = iris.data
y = iris.target

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=1)

# Tạo mô hình cây quyết định
clf = DecisionTreeClassifier()


# Huấn luyện mô hình
clf = clf.fit(X_train, y_train)

# Dự đoán trên tập kiểm tra
y_pred = clf.predict(X_test)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán cho vay tín dụng

Cây quyết định minh họa cho kết quả vay dựa trên thu nhập, năm làm việc và tiền án



Tập Train			
Income	Year_job	Criminal	Loan
10	1	0	0
30	3	0	0
50	4	0	1
70	5	1	0
90	7	0	1
50	2	0	0

Tập Test			
Income	Year_job	Criminal	Loan
50	1	0	?
50	5	0	?

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


4. Rừng ngẫu nhiên (Random Forest)

Cách hoạt động:

Rừng ngẫu nhiên là một thuật toán ensemble, kết hợp nhiều cây quyết định để đưa ra dự đoán chính xác hơn. Mỗi cây được xây dựng trên một tập con ngẫu nhiên của dữ liệu và tập hợp các thuộc tính, sau đó kết quả của các cây được kết hợp lại (đa số phiếu trong phân loại, trung bình trong hồi quy).

Ví dụ:

- Dự đoán gian lận thẻ tín dụng: Phát hiện giao dịch bất thường dựa trên lịch sử giao dịch.
- Phân loại hình ảnh: Nhận dạng đối tượng trong hình ảnh.




CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ưu điểm:


- **Giảm quá khớp:** Bằng cách kết hợp nhiều cây, mô hình giảm nguy cơ quá khớp.
- **Độ chính xác cao:** Thường cho kết quả tốt hơn so với một cây quyết định đơn lẻ.
- **Xử lý dữ liệu thiếu:** Có khả năng xử lý dữ liệu bị mất mát hoặc không hoàn chỉnh.

Nhược điểm:

- **Khó giải thích:** Mô hình phức tạp hơn, khó giải thích kết quả so với cây quyết định đơn lẻ.
- **Tính toán nặng:** Yêu cầu nhiều tài nguyên tính toán hơn, đặc biệt với dữ liệu lớn.
- **Không phù hợp với dữ liệu thời gian thực:** Do thời gian huấn luyện lâu.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



Thuật toán Random Forests

Hoạt động theo bốn bước:

1. Chọn các mẫu ngẫu nhiên từ tập dữ liệu đã cho.
2. Thiết lập cây quyết định cho từng mẫu và nhận kết quả dự đoán từ mỗi quyết định cây.
3. Hãy bỏ phiếu cho mỗi kết quả dự đoán.
4. Chọn kết quả được dự đoán nhiều nhất là dự đoán cuối cùng.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

```
import numpy as np
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn import metrics

# Tải dữ liệu mẫu
iris = load_iris()
X = iris.data
y = iris.target

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=1)

# Tạo mô hình rừng ngẫu nhiên
clf = RandomForestClassifier(n_estimators=100)

# Huấn luyện mô hình
clf.fit(X_train, y_train)

# Dự đoán trên tập kiểm tra
y_pred = clf.predict(X_test)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán mắc bệnh tim

Original Heart Disease Data				
	Age	Blood_Pressure	Heart_Rate	Has_Heart_Disease
1	45	120	75	0
2	60	140	85	1
3	50	130	80	1
4	55	150	90	1
5	40	110	70	0
6	65	160	95	1
7	35	115	65	0
8	70	155	88	1
9	50	135	82	1
10	58	145	87	1

Train Data Heart Disease					
		Age	Blood_Pressure	Heart_Rate	Has_Heart_Disease
1	0	45	120	75	0
2	7	70	155	88	1
3	2	50	130	80	1
4	9	58	145	87	1
5	4	40	110	70	0
6	3	55	150	90	1
7	6	35	115	65	0

Test Data Heart Disease Before Prediction				
		Age	Blood_Pressure	Heart_Rate
1	8	50	135	82
2	1	60	140	85
3	5	65	160	95

Tách tập gốc ra 2 tập train (70%) và test (30%) để huấn luyện và kiểm tra

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán mắc bệnh tim

Cây quyết định minh họa cho việc phân loại bệnh nhân có mắc bệnh tim hay không

Heart_Rate ≤ 76.0
gini = 0.408
samples = 7
value = [2, 5]
class = Heart Disease

gini = 0.0
samples = 2
value = [2, 0]
class = No Heart Disease

gini = 0.0
samples = 5
value = [0, 5]
class = Heart Disease

Kết quả kiểm tra

Heart Disease Test Results

		Age	Blood_Pressure	Heart_Rate	Predicted_Heart_Disease
1	8	50	135	82	1
2	1	60	140	85	1
3	5	65	160	95	1

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


5. Máy vector hỗ trợ (Support Vector Machines - SVM)

Cách hoạt động:

SVM là thuật toán phân loại và hồi quy sử dụng nguyên tắc tìm kiếm siêu phẳng tối ưu để phân tách dữ liệu thành các lớp. Mục tiêu là tìm ra biên giới quyết định (decision boundary) với khoảng cách lớn nhất đến các điểm dữ liệu gần nhất của mỗi lớp (các vector hỗ trợ).

Ví dụ:

- **Phân loại văn bản:** Phân loại email, tin tức, tài liệu thành các chủ đề khác nhau.
- **Nhận dạng chữ viết tay:** Phân loại các ký tự viết tay trong nhận dạng chữ số.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


5. Máy vector hỗ trợ (Support Vector Machines - SVM)

Cách hoạt động:

SVM là thuật toán phân loại và hồi quy sử dụng nguyên tắc tìm kiếm siêu phẳng tối ưu để phân tách dữ liệu thành các lớp. Mục tiêu là tìm ra biên giới quyết định (decision boundary) với khoảng cách lớn nhất đến các điểm dữ liệu gần nhất của mỗi lớp (các vector hỗ trợ).

Ví dụ:

- Phân loại văn bản: Phân loại email, tin tức, tài liệu thành các chủ đề khác nhau.
- Nhận dạng chữ viết tay: Phân loại các ký tự viết tay trong nhận dạng chữ số.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


Ưu điểm:

- **Hiệu quả với không gian chiều cao:** Hoạt động tốt khi số chiều của dữ liệu lớn hơn số mẫu.
- **Sử dụng các hàm kernel:** Có thể xử lý dữ liệu phi tuyến bằng cách sử dụng các hàm kernel để ánh xạ dữ liệu vào không gian chiều cao hơn.
- **Tổng quát hóa tốt:** Thường có khả năng tổng quát hóa tốt với dữ liệu chưa thấy.

Nhược điểm:







- **Khó lựa chọn hàm kernel:** Việc chọn hàm kernel phù hợp có thể phức tạp.
- **Thời gian tính toán lâu:** Với tập dữ liệu lớn, thời gian huấn luyện có thể rất lâu.
- **Không cung cấp xác suất trực tiếp:** SVM không đưa ra xác suất thuộc về một lớp mà chỉ đưa ra quyết định phân loại.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT




Support Vectors hiểu một cách đơn giản là các đối tượng trên đồ thị tọa độ quan sát, *Support Vector Machine* là một biên giới để chia hai lớp tốt nhất.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


Margin trong SVM



Margin là khoảng cách giữa siêu phẳng đến 2 điểm dữ liệu gần nhất tương ứng với các phân lớp. Trong ví dụ quả táo quả lê đặt trên mặt bàn, margin chính là khoảng cách giữa cây que và hai quả táo và lê gần nó nhất. Điều quan trọng ở đây đó là phương pháp SVM luôn cố gắng cực đại hóa margin này, từ đó thu được một siêu phẳng tạo khoảng cách xa nhất so với 2 quả táo và lê. Nhờ vậy, SVM có thể giảm thiểu việc phân lớp sai (misclassification) đối với điểm dữ liệu mới đưa vào

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Kết luận: SVM là một phương pháp hiệu quả cho bài toán phân lớp dữ liệu. Nó là một công cụ đặc lực cho các bài toán về xử lý ảnh, phân loại văn bản, phân tích quan điểm. Một yếu tố làm nên hiệu quả của SVM đó là việc sử dụng **Kernel function** khiến cho các phương pháp chuyển không gian trở nên linh hoạt hơn.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

```
import numpy as np
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn import metrics

# Tải dữ liệu mẫu
iris = load_iris()
X = iris.data
y = iris.target

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=1)

# Tạo mô hình SVM
svm_model = SVC(kernel='linear')

# Huấn luyện mô hình
svm_model.fit(X_train, y_train)

# Dự đoán trên tập kiểm tra
y_pred = svm_model.predict(X_test)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán loài hoa diên vĩ (iris)

Iris Dataset Sample			
	Sepal Length	Sepal Width	Species
1	6.1	2.8	versicolor
2	5.7	3.8	setosa
3	7.7	2.6	virginica
4	6.0	2.9	versicolor
5	6.8	2.8	versicolor
6	5.4	3.4	setosa
7	5.6	2.9	versicolor
8	6.9	3.1	virginica
9	6.2	2.2	versicolor
10	5.8	2.7	versicolor


Tách tập gốc ra 2 tập train (70%) và test (30%) để huấn luyện và kiểm tra

Training Dataset			
	Sepal Length	Sepal Width	Species
1	5.5	2.4	versicolor
2	6.3	2.8	virginica
3	6.4	3.1	virginica
4	6.6	3.0	versicolor
5	7.2	3.6	virginica
6	5.7	2.9	versicolor
7	7.6	3.0	virginica
8	5.6	3.0	versicolor
9	5.1	3.5	setosa
10	7.7	2.8	virginica

Testing Dataset (No Species)			
	Sepal Length	Sepal Width	
1	6.1	2.8	
2	5.7	3.8	
3	7.7	2.6	
4	6.0	2.9	
5	6.8	2.8	
6	5.4	3.4	
7	5.6	2.9	
8	6.9	3.1	
9	6.2	2.2	
10	5.8	2.7	

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


Ví dụ: Bài toán dự đoán loài hoa diên vĩ (iris)



Kết quả kiểm tra

Testing Dataset			
	Sepal Length	Sepal Width	Species
1	6.1	2.8	versicolor
2	5.7	3.8	setosa
3	7.7	2.6	virginica
4	6.0	2.9	versicolor
5	6.8	2.8	versicolor
6	5.4	3.4	setosa
7	5.6	2.9	versicolor
8	6.9	3.1	virginica
9	6.2	2.2	versicolor
10	5.8	2.7	versicolor

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



6. K-Nearest Neighbors (KNN)

Cách hoạt động:

KNN là một thuật toán phân loại và hồi quy dựa trên khoảng cách. Đối với một mẫu dữ liệu mới, KNN tìm kiếm K điểm dữ liệu gần nhất trong không gian đặc trưng và dựa vào nhãn của các điểm này để dự đoán nhãn cho mẫu mới (đa số phiếu trong phân loại, trung bình trong hồi quy).

Ví dụ:

- **Nhận dạng mẫu:** Phân loại hình ảnh, nhận dạng khuôn mặt.
- **Hệ thống gợi ý:** Gợi ý sản phẩm dựa trên hành vi mua sắm của khách hàng tương tự.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


Ưu điểm:

- **Đơn giản và dễ hiểu:** Thuật toán dễ triển khai và trực quan.
- **Không yêu cầu huấn luyện:** KNN là thuật toán dựa trên ví dụ (instance-based), không có giai đoạn huấn luyện mô hình.
- **Linh hoạt:** Có thể sử dụng cho cả phân loại và hồi quy.

Nhược điểm:

- **Chi phí tính toán cao:** Tốc độ dự đoán chậm với tập dữ liệu lớn do cần tính khoảng cách đến tất cả các điểm dữ liệu.
- **Nhạy cảm với dữ liệu nhiễu:** Các điểm ngoại lai có thể ảnh hưởng đến kết quả.
- **Cần lựa chọn K phù hợp:** Giá trị K ảnh hưởng lớn đến hiệu suất của mô hình.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



Các bước trong KNN

1. Ta có D là tập các điểm dữ liệu đã được gán nhãn và A là dữ liệu chưa được phân loại.
2. Đo khoảng cách (Euclidian, Manhattan, Minkowski, Minkowski hoặc Trọng số) từ dữ liệu mới A đến tất cả các dữ liệu khác đã được phân loại trong D.
3. Chọn K (K là tham số mà bạn định nghĩa) khoảng cách nhỏ nhất.
4. Kiểm tra danh sách các lớp có khoảng cách gần nhất và đếm số lượng của mỗi lớp xuất hiện.
5. Lấy đúng lớp (lớp xuất hiện nhiều lần nhất).
6. Lớp của dữ liệu mới là lớp mà bạn đã nhận được ở bước 5.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

```
import numpy as np
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn import metrics

# Tải dữ liệu mẫu
iris = load_iris()
X = iris.data
y = iris.target

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=1)

# Tạo mô hình KNN với k=3
knn = KNeighborsClassifier(n_neighbors=3)

# Huấn luyện mô hình
knn.fit(X_train, y_train)


# Dự đoán trên tập kiểm tra
y_pred = knn.predict(X_test)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán khả năng vỡ nợ dựa vào độ tuổi và khoản vay

Sample Dataset			
☐	Age	Loan	Default
1	25	40000	N
2	35	60000	N
3	45	80000	N
4	20	20000	N
5	30	120000	Y
6	40	95000	Y
7	60	100000	Y
8	38	220000	Y
9	48	62000	N
10	33	150000	Y

Dự đoán cho người 48 tuổi vay \$142,000: Vỡ nợ



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

7. Naive Bayes


Cách hoạt động:

Naive Bayes là một nhóm các thuật toán phân loại dựa trên định lý Bayes với giả định độc lập giữa các biến độc lập (giả định đơn giản). Mô hình tính toán xác suất một mẫu thuộc về một lớp nhất định dựa trên xác suất có điều kiện của các đặc trưng.

Công thức định lý Bayes:

$$P(C|X) = \frac{P(X|C) \cdot P(C)}{P(X)}$$

- $P(C|X)$: Xác suất mẫu thuộc lớp C cho trước đặc trưng X.
- $P(X|C)$: Xác suất xuất hiện đặc trưng X khi biết mẫu thuộc lớp C.
- $P(C)$: Xác suất mẫu thuộc lớp C.
- $P(X)$: Xác suất xuất hiện đặc trưng X.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ưu điểm:

- **Tốc độ nhanh:** Hoạt động nhanh với tập dữ liệu lớn.
- **Hiệu quả với dữ liệu cao chiều:** Phù hợp khi số lượng biến độc lập lớn.
- **Đơn giản và hiệu quả:** Dễ triển khai và thường cho kết quả tốt.

Nhược điểm:

- **Giả định độc lập:** Giả định các biến độc lập có thể không thực tế trong nhiều trường hợp.
- **Không phù hợp với dữ liệu liên tục:** Cần xử lý đặc biệt cho dữ liệu liên tục hoặc sử dụng các biến rời rạc.

Ví dụ:

- **Lọc thư rác:** Phân loại email là thư rác hay không dựa trên từ ngữ xuất hiện trong email.
- **Phân loại tài liệu:** Gán nhãn chủ đề cho các văn bản.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ưu điểm:

- **Tốc độ nhanh:** Hoạt động nhanh với tập dữ liệu lớn.
- **Hiệu quả với dữ liệu cao chiều:** Phù hợp khi số lượng biến độc lập lớn.
- **Đơn giản và hiệu quả:** Dễ triển khai và thường cho kết quả tốt.

Nhược điểm:

- **Giả định độc lập:** Giả định các biến độc lập có thể không thực tế trong nhiều trường hợp.
- **Không phù hợp với dữ liệu liên tục:** Cần xử lý đặc biệt cho dữ liệu liên tục hoặc sử dụng các biến rời rạc.

Ví dụ:

- **Lọc thư rác:** Phân loại email là thư rác hay không dựa trên từ ngữ xuất hiện trong email.
- **Phân loại tài liệu:** Gán nhãn chủ đề cho các văn bản.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

NAIVE BAYES CLASSIFIER


$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}$$

Công thức chỉ ra xác suất của A xảy ra nếu B cũng xảy ra, ta viết là $P(A|B)$. Và nếu ta biết xác suất của B xảy ra khi biết A, ta viết là $P(B|A)$ cũng như xác suất độc lập của A và B.

- $P(A|B)$ là “xác suất của A khi biết B”
- $P(A)$ là xác suất xảy ra của A
- $P(B|A)$ là “xác suất của B khi biết A”
- $P(B)$ là xác suất xảy ra của B

Ví dụ, $P(\text{lửa})$ là xác suất có lửa, $P(\text{khói})$ là xác suất ta nhìn thấy khói. Ta sẽ có những trường hợp sau:

$P(\text{Lửa} | \text{Khói})$ có nghĩa là tần suất có lửa khi chúng ta nhìn thấy khói. $P(\text{Khói} | \text{Lửa})$ có nghĩa là chúng ta thường thấy khói khi có lửa.

Công thức sẽ cho chúng ta biết được điều gì xảy ra tiếp theo nếu ta đã biết một điều.

Ví dụ: Một đám cháy nguy hiểm là có xác suất là 1% nhưng khói lại khá phổ biến là 10% (từ các nhà máy) và 90% đám cháy nguy hiểm tạo ra khói. Vậy ta có:

$$P(\text{Lửa} | \text{Khói}) = P(\text{Lửa}) P(\text{Khói} | \text{Lửa}) = 1\% \times 90\% = 9\% P(\text{Khói}) 10\%$$

Trong trường hợp này, 9% khả năng thấy khói có nghĩa là có một đám cháy nguy hiểm.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Bài toán dự đoán mắc bệnh ung thư

```
# Import các thư viện cần thiết
import numpy as np
import pandas as pd
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB

# Tải bộ dữ liệu ung thư vú
data = load_breast_cancer()
X = data.data # Đặc trưng
y = data.target # Nhãn (0: lành tính, 1: Ác tính)

# Chia dữ liệu thành tập huấn luyện và tập kiểm tra (80% huấn luyện, 20% kiểm tra)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Tạo mô hình Naive Bayes (GaussianNB)
model = GaussianNB()

# Huấn luyện mô hình
model.fit(X_train, y_train)

# Dự đoán trên tập kiểm tra
y_pred = model.predict(X_test)
```

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


8. Mạng nơ-ron nhân tạo (Artificial Neural Networks - ANN)

Cách hoạt động:

ANN là mô hình lấy cảm hứng từ cấu trúc và chức năng của não người. Mạng gồm nhiều lớp (input, hidden, output), mỗi lớp có nhiều nút (neurons) kết nối với nhau. Mô hình học bằng cách điều chỉnh trọng số kết nối giữa các nút để giảm thiểu sai số dự đoán thông qua quá trình lan truyền ngược (backpropagation).

Ví dụ:

- Nhận dạng hình ảnh: Phân loại đối tượng trong hình ảnh, nhận diện khuôn mặt.
- Xử lý ngôn ngữ tự nhiên: Dịch máy, phân tích cảm xúc, tạo văn bản tự động.



CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT


Ưu điểm:

- **Khả năng mô hình hóa phi tuyến mạnh mẽ:** Xử lý tốt các mối quan hệ phi tuyến giữa biến độc lập và phụ thuộc.
- **Độ linh hoạt cao:** Có thể áp dụng cho nhiều loại dữ liệu và bài toán khác nhau.
- **Học từ dữ liệu phức tạp:** Phù hợp với dữ liệu lớn và phức tạp như hình ảnh, âm thanh.

Nhược điểm:

- **Thời gian huấn luyện dài:** Yêu cầu nhiều tài nguyên tính toán và thời gian huấn luyện lâu.
- **Khó giải thích:** Mô hình như một "hộp đen", khó hiểu rõ cách thức ra quyết định.
- **Nguy cơ quá khớp:** Cần kỹ thuật đặc biệt để tránh quá khớp, như regularization hoặc dropout.

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT




CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Epoch 1/10	15/15	2s 1ms/step	- accuracy: 0.7428	- loss: 0.5648
Epoch 2/10	15/15	0s 1ms/step	- accuracy: 0.8518	- loss: 0.4110
Epoch 3/10	15/15	0s 1ms/step	- accuracy: 0.9281	- loss: 0.3208
Epoch 4/10	15/15	0s 1ms/step	- accuracy: 0.9233	- loss: 0.2902
Epoch 5/10	15/15	0s 1ms/step	- accuracy: 0.9391	- loss: 0.2367
Epoch 6/10	15/15	0s 1ms/step	- accuracy: 0.9341	- loss: 0.2033
Epoch 7/10	15/15	0s 1ms/step	- accuracy: 0.9473	- loss: 0.1746
Epoch 8/10	15/15	0s 1ms/step	- accuracy: 0.9150	- loss: 0.1898
Epoch 9/10	15/15	0s 1ms/step	- accuracy: 0.9317	- loss: 0.1626
Epoch 10/10	15/15	0s 1ms/step	- accuracy: 0.9399	- loss: 0.1525

Epoch: Huấn luyện mô hình trong **10 epochs**. Một epoch tương ứng với việc toàn bộ dữ liệu huấn luyện đã đi qua mạng nơ-ron một lần.

Accuracy (Độ chính xác): Độ chính xác của mô hình càng tăng theo mỗi epoch, điều này cho thấy mô hình đang học tốt hơn sau mỗi lần huấn luyện

Loss (Mất mát): Giá trị mất mát biểu thị sự khác biệt giữa dự đoán của mô hình và kết quả thực tế (mục tiêu).



Kiến trúc 10 nơ-ron cho lớp đầu vào, 8 cho lớp ẩn, và 1 cho lớp đầu ra

CÁC THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

9. Gradient Boosting Machines (GBM) và XGBoost

Cách hoạt động:

GBM và XGBoost là các thuật toán ensemble xây dựng mô hình dự đoán mạnh bằng cách kết hợp nhiều mô hình yếu (thường là cây quyết định) theo phương pháp boosting. Mỗi mô hình mới được xây dựng để sửa lỗi của mô hình trước đó, tập trung vào các mẫu khó dự đoán.

Ưu điểm:


- Độ chính xác cao: Thường cho kết quả dự đoán xuất sắc.
- Xử lý dữ liệu phi tuyến: Mô hình hóa tốt các mối quan hệ phức tạp.
- Linh hoạt: Có thể điều chỉnh nhiều tham số để tối ưu hóa mô hình.

Nhược điểm:


- Thời gian huấn luyện lâu: Yêu cầu nhiều thời gian và tài nguyên tính toán.
- Nguy cơ quá khớp: Cần điều chỉnh cẩn thận để tránh quá khớp.
- Khó giải thích: Mô hình phức tạp, khó giải thích kết quả.

Ví dụ:

- Dự đoán rủi ro tín dụng: Đánh giá khả năng vỡ nợ của khách hàng.
- Cuộc thi khoa học dữ liệu: Thường được sử dụng trong các cuộc thi như Kaggle do hiệu suất cao.



Ensemble Method hay gọi một cách Việt hóa là Học Kết Hợp, là một phương pháp với tư tưởng là **Thay vì cố gắng xây dựng một mô hình tốt duy nhất, chúng ta sẽ xây dựng một họ các mô hình yếu hơn một chút, nhưng khi kết hợp các mô hình lại, (nếu có thể kết hợp một cách chính xác) sẽ thu được một mô hình còn vượt trội hơn cả.**



ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Trong học máy có giám sát (Supervised Learning), sau khi xây dựng mô hình, bước tiếp theo là đánh giá hiệu quả của mô hình để đảm bảo rằng nó hoạt động tốt trên dữ liệu mới, chưa được nhìn thấy trong quá trình huấn luyện. Dưới đây là các phương pháp phổ biến để đánh giá mô hình học có giám sát:

1. Phân chia tập huấn luyện và tập kiểm tra (Train-Test Split)

Cách hoạt động:

- Dữ liệu được chia thành hai phần: **tập huấn luyện** và **tập kiểm tra**.
- Mô hình được huấn luyện trên tập huấn luyện và được kiểm tra trên tập kiểm tra. Kết quả đánh giá trên tập kiểm tra sẽ cho biết mô hình có hoạt động tốt trên dữ liệu mới hay không.

Ví dụ:

- Chia dữ liệu thành 80% huấn luyện và 20% kiểm tra. Mô hình sẽ học từ 80% dữ liệu và được đánh giá trên 20% còn lại.

Ưu điểm:

- Dễ triển khai và hiểu rõ cách thức hoạt động.
- Đơn giản và trực tiếp.

Nhược điểm:

- Kết quả có thể không đại diện nếu dữ liệu kiểm tra quá ít hoặc không đủ đa dạng.
- Không tận dụng được toàn bộ dữ liệu cho việc huấn luyện.

2. Cross-Validation (K-fold Cross-Validation)

Cách hoạt động:

- K-fold Cross-Validation** là một kỹ thuật chia dữ liệu thành **K** phần bằng nhau. Mỗi phần được dùng làm tập kiểm tra một lần và các phần còn lại làm tập huấn luyện.
- Quá trình này lặp lại **K** lần, và kết quả được lấy trung bình từ **K** lần **thử nghiệm** để có được đánh giá chính xác hơn.

Ví dụ:

- Với **5-fold cross-validation**, dữ liệu được chia thành 5 phần bằng nhau. Mô hình sẽ được huấn luyện 5 lần, mỗi lần giữ lại 1 phần để kiểm tra và 4 phần còn lại để huấn luyện.

Ưu điểm:

- Giúp tận dụng toàn bộ dữ liệu để huấn luyện và kiểm tra.
- Giảm nguy cơ gặp phải dữ liệu không đại diện khi chia tập kiểm tra một lần duy nhất.

Nhược điểm:

- Tốn nhiều thời gian và tài nguyên tính toán hơn vì phải huấn luyện mô hình nhiều lần.

ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

3. Leave-One-Out Cross-Validation (LOOCV)

Cách hoạt động:

- **Leave-One-Out Cross-Validation (LOOCV)** là một trường hợp đặc biệt của **K-fold cross-validation**, trong đó **K** bằng với số lượng mẫu dữ liệu. Mỗi mẫu được giữ lại làm tập kiểm tra một lần, và tất cả các mẫu còn lại được dùng để huấn luyện.
- Quá trình này lặp lại cho đến khi tất cả các mẫu đều được sử dụng làm tập kiểm tra một lần.

Ví dụ:

- Nếu có 100 mẫu dữ liệu, sẽ có 100 lần huấn luyện, mỗi lần sử dụng 99 mẫu để huấn luyện và 1 mẫu để kiểm tra.

Ưu điểm:

- Tận dụng triệt để dữ liệu, vì mỗi mẫu đều được dùng để kiểm tra.
- Không lãng phí dữ liệu cho quá trình kiểm tra, phù hợp khi số lượng mẫu dữ liệu ít.

Nhược điểm:

- Rất tốn thời gian và tài nguyên, đặc biệt khi số lượng mẫu lớn.

4. Confusion Matrix (Ma trận nhầm lẫn)

Cách hoạt động:

- **Confusion Matrix** là một công cụ để đánh giá kết quả của mô hình phân loại, đặc biệt là các mô hình phân loại nhị phân. Nó cho thấy tần suất các dự đoán chính xác và sai, bao gồm:
 - **True Positive (TP)**: Dự đoán đúng là dương tính.
 - **True Negative (TN)**: Dự đoán đúng là âm tính.
 - **False Positive (FP)**: Dự đoán sai là dương tính (nhầm âm tính thành dương tính).
 - **False Negative (FN)**: Dự đoán sai là âm tính (nhầm dương tính thành âm tính).

Ví dụ:

- Trong một bài toán phân loại ung thư, **TP** là số bệnh nhân được dự đoán mắc bệnh và thực sự mắc bệnh, **FP** là số bệnh nhân bị dự đoán mắc bệnh nhưng không mắc, và ngược lại.

Ưu điểm:

- Giúp phân tích chi tiết hơn về hiệu suất của mô hình phân loại.
- Xác định được loại lỗi mà mô hình hay mắc phải (FP hoặc FN).

Nhược điểm:

- Đối với các bài toán phân loại nhiều lớp, ma trận nhầm lẫn trở nên phức tạp và khó diễn giải hơn.

ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

5. Accuracy (Độ chính xác)

Cách hoạt động:

- **Accuracy** là tỷ lệ giữa số dự đoán đúng và tổng số dự đoán. Nó đo lường phần trăm các dự đoán đúng của mô hình trên tổng số các mẫu.

Ví dụ:

- Nếu mô hình dự đoán đúng 90 trên 100 mẫu, thì độ chính xác là 90%.

Ưu điểm:

- Đơn giản và dễ hiểu.
- Hiệu quả trong các bài toán phân loại mà các lớp có phân phối đồng đều.

Nhược điểm:

- Không phù hợp khi dữ liệu mất cân bằng (ví dụ: bài toán có 95% mẫu thuộc một lớp, accuracy sẽ cao mà không phản ánh đúng khả năng mô hình).

6. Precision, Recall, và F1-Score

Cách hoạt động:

- **Precision (Độ chính xác của dương tính)**: Là tỷ lệ số dự đoán đúng dương tính trên tổng số mẫu được dự đoán là dương tính ($\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$).
- **Recall (Độ nhạy)**: Là tỷ lệ số dự đoán đúng dương tính trên tổng số mẫu thực sự dương tính ($\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$).
- **F1-Score**: Là trung bình điều hòa giữa Precision và Recall, cho một số đo tổng hợp hiệu suất của mô hình ($\text{F1} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$).

Ví dụ:

- Trong bài toán phân loại ung thư, **Precision** đo tỷ lệ bệnh nhân được dự đoán mắc bệnh mà thực sự mắc bệnh. **Recall** đo tỷ lệ bệnh nhân thực sự mắc bệnh mà được dự đoán đúng.

Ưu điểm:

- Cung cấp thông tin chi tiết hơn về khả năng mô hình so với độ chính xác.
- Thích hợp cho các bài toán có dữ liệu mất cân bằng.

Nhược điểm:

- Cần phải tính toán thêm, không đơn giản như accuracy.

ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Để đơn giản hóa, ta sẽ sử dụng lại bài toán về chẩn đoán ung thư để giải thích 4 chỉ số này. Trong bài toán chẩn đoán ung thư ta có 2 lớp: lớp bị ung thư được chẩn đoán Positive và lớp không bị ung thư được chẩn đoán là Negative:

- TP (True Positive): Số lượng dự đoán chính xác. Là khi mô hình dự đoán đúng một người bị ung thư.
- TN (True Negative): Số lượng dự đoán chính xác một cách gián tiếp. Là khi mô hình dự đoán đúng một người không bị ung thư, tức là việc không chọn trường hợp bị ung thư là chính xác.
- FP (False Positive - Type 1 Error): Số lượng các dự đoán sai lệch. Là khi mô hình dự đoán một người bị ung thư và người đó hoàn toàn khỏe mạnh.
- FN (False Negative - Type 2 Error): Số lượng các dự đoán sai lệch một cách gián tiếp. Là khi mô hình dự đoán một người không bị ung thư nhưng người đó bị ung thư, tức là việc không chọn trường hợp bị ung thư là sai. Từ 4 chỉ số này, ta có 2 con số để đánh giá mức độ tin cậy của một mô hình:

Precision: Trong tất cả các dự đoán Positive được đưa ra, bao nhiêu dự đoán là chính xác? Chỉ số này được tính theo công thức:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall: Trong tất cả các trường hợp Positive, bao nhiêu trường hợp đã được dự đoán chính xác? Chỉ số này được tính theo công thức:

$$\text{Recall} = \frac{TP}{TP + FN}$$

ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

7. AUC-ROC (Area Under Curve - Receiver Operating Characteristic)

Cách hoạt động:

- AUC-ROC là một công cụ đánh giá hiệu suất của các mô hình phân loại nhị phân bằng cách so sánh tỷ lệ True Positive (TPR) với False Positive (FPR) khi thay đổi ngưỡng phân loại.
- AUC là diện tích dưới đường cong ROC, giá trị AUC càng lớn thì mô hình càng tốt.

Ví dụ:


- Trong bài toán dự đoán ung thư, AUC-ROC giúp đánh giá hiệu suất của mô hình ở nhiều ngưỡng phân loại khác nhau.

Ưu điểm:

- Cung cấp cái nhìn tổng quát về hiệu suất của mô hình cho nhiều ngưỡng phân loại.
- Hiệu quả khi dữ liệu bị mất cân bằng.

Nhược điểm:

- Khó giải thích trực tiếp, cần đồ thị để trực quan hóa.



ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Tổng kết:

Phương pháp	Mô tả	Ưu điểm	Nhược điểm
Accuracy	Tỷ lệ dự đoán đúng trên tổng số mẫu	Đơn giản, dễ tính toán	Không hiệu quả với dữ liệu không cân bằng
Confusion Matrix	Hiển thị số lượng dự đoán đúng và sai cho từng lớp	Chi tiết hơn về từng loại lỗi	Khó diễn giải với nhiều lớp
Precision, Recall, F1	Đánh giá chi tiết hiệu suất của mô hình dựa trên dự đoán đúng và sai cho từng lớp	Cung cấp thông tin về loại lỗi (FP/FN)	Chỉ tập trung vào một khía cạnh nếu không dùng F1-Score
Cross-Validation	Chia dữ liệu thành nhiều tập kiểm tra và huấn luyện để có đánh giá toàn diện	Giúp kiểm tra kỹ lưỡng mô hình	Tốn thời gian, yêu cầu nhiều tài nguyên
ROC-AUC	Đánh giá khả năng phân loại của mô hình ở nhiều ngưỡng phân loại khác nhau	Hiệu quả cho bài toán phân loại nhị phân, dữ liệu mất cân bằng	Khó diễn giải với phân loại đa lớp

ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

Ví dụ: Dự đoán khả năng sống sót của hành khách trên tàu Titanic dựa trên các thông tin như độ tuổi, giới tính, hạng vé, và các đặc trưng khác., đánh giá các thuật toán KNN, SVM, Naïve Bayes

==== Support Vector Machine ====

Accuracy: 0.83

Classification Report:

	precision	recall	f1-score	support
0	0.80	0.91	0.85	80
1	0.87	0.71	0.78	63
accuracy			0.83	143
macro avg	0.83	0.81	0.82	143
weighted avg	0.83	0.83	0.82	143

==== K-Nearest Neighbors ====

Accuracy: 0.80

Classification Report:

	precision	recall	f1-score	support
0	0.80	0.86	0.83	80
1	0.81	0.73	0.77	63
accuracy			0.80	143
macro avg	0.80	0.80	0.80	143
weighted avg	0.80	0.80	0.80	143




==== Naïve Bayes ====

Accuracy: 0.72

Classification Report:


	precision	recall	f1-score	support
0	0.75	0.75	0.75	80
1	0.68	0.68	0.68	63
accuracy			0.72	143
macro avg	0.72	0.72	0.72	143
weighted avg	0.72	0.72	0.72	143

ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT



ĐÁNH GIÁ THUẬT TOÁN HỌC MÁY CÓ GIÁM SÁT

K-Nearest Neighbors - Cross-Validation Accuracy: 0.78
Support Vector Machine - Cross-Validation Accuracy: 0.82
Naïve Bayes - Cross-Validation Accuracy: 0.76



K-Fold Cross-Validation là phương pháp chia dữ liệu thành K phần bằng nhau. Mỗi phần lần lượt được sử dụng làm tập kiểm tra, và các phần còn lại là tập huấn luyện. Kết quả đánh giá là trung bình của K lần kiểm tra.

- **ROC-AUC** là một chỉ số đánh giá khả năng phân loại của mô hình, đặc biệt trong các bài toán phân loại nhị phân. **ROC Curve** là đồ thị so sánh giữa **True Positive Rate (Recall)** và **False Positive Rate** ở nhiều ngưỡng phân loại khác nhau.
- **AUC (Area Under Curve)** là diện tích dưới đường cong ROC, giá trị AUC càng lớn (gần 1) thì mô hình càng tốt.

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

1. K-Means Clustering (Phân cụm K-Means)

a. Cách hoạt động:

K-Means là một thuật toán phân cụm được sử dụng để chia dữ liệu thành K nhóm (clusters) dựa trên khoảng cách giữa các điểm dữ liệu. Mỗi điểm dữ liệu được gán vào cụm có tâm (centroid) gần nhất.

b. Cách thực hiện:

1. Chọn K số cụm.
2. Chọn ngẫu nhiên K điểm ban đầu làm tâm cụm.
3. Gán mỗi điểm dữ liệu vào cụm có tâm cụm gần nhất.
4. Cập nhật tâm cụm bằng cách tính trung bình các điểm trong mỗi cụm.
5. Lặp lại cho đến khi các tâm cụm không thay đổi.

c. Ưu điểm:


- Đơn giản và nhanh.
- Hiệu quả với dữ liệu có cấu trúc phân cụm rõ ràng.

d. Nhược điểm:

- Cần xác định trước số lượng cụm K .
- Nhạy cảm với điểm khởi tạo ngẫu nhiên.
- Dễ bị ảnh hưởng bởi các outliers (điểm bất thường).

e. Ứng dụng:

- Phân nhóm khách hàng (Customer Segmentation).
- Phân nhóm ảnh.



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT



K-Mean

```
import warnings
from sklearn.cluster import KMeans
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt
# Bỏ qua tất cả cảnh báo
warnings.filterwarnings("ignore")

# Dữ liệu Iris
iris = load_iris()
X = iris.data

# Áp dụng K-Means với 3 cụm
kmeans = KMeans(n_clusters=3, n_init=10)
kmeans.fit(X)

# Hiển thị kết quả phân cụm
plt.scatter(X[:, 0], X[:, 1], c=kmeans.labels_)
plt.title('K-Means Clustering')
plt.show()
```



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

1. Phương pháp Elbow (Khuyết tay)

Phương pháp **Elbow** giúp xác định số cụm K bằng cách tính tổng bình phương các khoảng cách của các điểm đến tâm cụm (SSE - Sum of Squared Errors) và quan sát sự thay đổi của nó khi tăng số cụm. Khi SSE giảm dần và tại một điểm nhất định giảm chậm lại, điểm này được gọi là "khuyết tay" (elbow) và là số cụm K hợp lý nhất.

Các bước:

1. Chạy K-Means với nhiều giá trị K khác nhau (ví dụ từ 1 đến 10).
2. Tính SSE cho mỗi giá trị K .
3. Vẽ đồ thị SSE theo K .
4. Chọn K tại điểm mà SSE bắt đầu giảm chậm lại (khuyết tay).

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT


Elow - Cách tính số cụm

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

# Giả lập dữ liệu
from sklearn.datasets import make_blobs
X, _ = make_blobs(n_samples=300, centers=4, cluster_std=0.60, random_state=42)

# Áp dụng phương pháp Elbow
sse = []
for k in range(1, 11):
    kmeans = KMeans(n_clusters=k, n_init=10, random_state=42)
    kmeans.fit(X)
    sse.append(kmeans.inertia_) # SSE (inertia_)

# Vẽ đồ thị Elbow
plt.plot(range(1, 11), sse, marker='o')
plt.xlabel('Số cụm (K)')
plt.ylabel('Tổng bình phương các khoảng cách (SSE)')
plt.title('Phương pháp Elbow')
plt.show()
```



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

2. Phương pháp Silhouette (Độ bóng)

Chỉ số **Silhouette** đo lường mức độ gắn kết của mỗi điểm dữ liệu trong cụm của nó và mức độ khác biệt với các cụm lân cận. Silhouette nằm trong khoảng từ -1 đến 1:

- **Gần 1:** Điểm được phân cụm tốt.
- **Gần 0:** Điểm ở biên giữa các cụm.
- **Gần -1:** Điểm bị phân vào cụm sai.

Số cụm K hợp lý là giá trị mà chỉ số Silhouette đạt giá trị lớn nhất.

Các bước:

1. Chạy K-Means với nhiều giá trị K .
2. Tính chỉ số Silhouette cho mỗi giá trị K .
3. Chọn K với chỉ số Silhouette cao nhất.


CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

Silhouette

```
from sklearn.metrics import silhouette_score

silhouette_scores = []
for k in range(2, 11): # Bắt đầu từ 2 cụm vì silhouette không xác định được cho K=1
    kmeans = KMeans(n_clusters=k, n_init=10, random_state=42)
    kmeans.fit(X)
    score = silhouette_score(X, kmeans.labels_)
    silhouette_scores.append(score)

# Vẽ đồ thị Silhouette
plt.plot(range(2, 11), silhouette_scores, marker='o')
plt.xlabel('Số cụm (K)')
plt.ylabel('Chỉ số Silhouette')
plt.title('Phương pháp Silhouette')
plt.show()
```



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

2. Hierarchical Clustering (Phân cụm phân cấp)


a. Cách hoạt động:

Hierarchical Clustering là phương pháp phân cụm dựa trên việc xây dựng một cây phân cấp (dendrogram). Có hai cách tiếp cận chính:

- **Agglomerative Clustering** (phân cụm kết hợp): Bắt đầu từ mỗi điểm là một cụm, rồi dần dần kết hợp chúng lại cho đến khi tất cả điểm nằm trong một cụm duy nhất.
- **Divisive Clustering** (phân cụm phân tách): Bắt đầu từ một cụm duy nhất chứa tất cả điểm, sau đó dần dần tách chúng ra.

b. Cách thực hiện (Agglomerative):

1. Xác định mỗi điểm dữ liệu là một cụm riêng biệt.
2. Tìm hai cụm gần nhau nhất và kết hợp chúng thành một cụm mới.
3. Tiếp tục cho đến khi chỉ còn một cụm duy nhất.



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

c. Ưu điểm:

- Không cần xác định trước số cụm.
- Dễ hiểu và trực quan khi xem qua dendrogram.

d. Nhược điểm:

- Tính toán tốn nhiều thời gian với dữ liệu lớn.
- Khó xác định số cụm từ dendrogram.

e. Ứng dụng:

- Phân tích biểu hiện gen.
- Phân tích phân cấp tài liệu.

f. Ví dụ trong Python:

Hierarchy Cluster


```
from scipy.cluster.hierarchy import dendrogram, linkage
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt

# Dữ liệu Iris
iris = load_iris()
X = iris.data

# Áp dụng phân cụm phân cấp (Agglomerative)
Z = linkage(X, method='ward')
plt.figure(figsize=(10, 7))
dendrogram(Z)
plt.title('Hierarchical Clustering Dendrogram')
plt.show()
```

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

Hierarchical Clustering Dendrogram



1. Cấu trúc Dendrogram:

- **Trục X:** Các điểm dữ liệu được xếp dọc theo trục X, với mỗi cột đại diện cho một điểm dữ liệu hoặc một cụm.
- **Trục Y:** Biểu thị khoảng cách hoặc độ tương tự giữa các cụm. Khoảng cách càng lớn trên trục Y, các cụm càng khác biệt nhau.

2. Nhận xét từ biểu đồ:

- Ở cấp độ cao nhất trên trục Y (khoảng trên 30), có **hai cụm chính** được hình thành, được thể hiện bởi hai nhánh lớn (màu xanh lá cây và màu cam).
- Từ hai cụm lớn này, nếu bạn cắt **Dendrogram** tại khoảng cách từ 10-15 trên trục Y, bạn có thể phân tách thành **ba cụm chính**:
 - Một cụm bên trái (màu cam) chứa các điểm dữ liệu mà khoảng cách giữa chúng gần hơn, cho thấy chúng có độ tương tự cao hơn.
 - Cụm lớn bên phải (màu xanh lá cây) có thể được chia tiếp thành hai cụm nhỏ hơn, mỗi cụm chứa các điểm dữ liệu với độ tương tự cao hơn trong nội bộ cụm của chúng.

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT


3. Principal Component Analysis (PCA) (Phân tích thành phần chính)

a. Cách hoạt động:

PCA là phương pháp giảm chiều dữ liệu, giữ lại những thông tin quan trọng nhất. Nó tìm các phương (components) mới sao cho giữ lại nhiều phương sai của dữ liệu nhất, đồng thời giảm số chiều.

b. Cách thực hiện:

1. Chuẩn hóa dữ liệu.
2. Tính ma trận hiệp phương sai.
3. Tìm các eigenvectors (vector riêng) và eigenvalues (giá trị riêng) của ma trận hiệp phương sai.
4. Chọn các thành phần chính có eigenvalues lớn nhất và chuyển dữ liệu sang không gian mới.



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

c. Ưu điểm:

- Giảm số chiều dữ liệu, giúp trực quan hóa dữ liệu dễ dàng hơn.
- Giảm thiểu hiện tượng quá khớp (overfitting) khi có nhiều đặc trưng.

d. Nhược điểm:

- Mất một số thông tin khi giảm chiều.
- Các thành phần chính không luôn có ý nghĩa rõ ràng.

e. Ứng dụng:

- Giảm chiều dữ liệu cho học máy.
- Trực quan hóa dữ liệu phức tạp.

f. Ví dụ trong Python:

PCA (phân tích thành phần chính)


```
from sklearn.decomposition import PCA
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt

# Dữ liệu Iris
iris = load_iris()
X = iris.data

# Áp dụng PCA, giảm xuống còn 2 chiều
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X)

# Hiển thị dữ liệu sau khi giảm chiều
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=iris.target)
plt.title('PCA - Iris Dataset')
plt.show()
```

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT



- **Phân tách rõ ràng giữa các loài:**
 - **Setosa (màu tím)** tách biệt rõ ràng so với hai loài còn lại (Versicolor và Virginica). Điều này cho thấy loài Setosa có các đặc trưng khác biệt mạnh so với hai loài kia, và việc phân loại Setosa dễ dàng hơn.
 - **Versicolor (màu xanh lá cây)** và **Virginica (màu vàng)** có phần giao nhau trong không gian PCA, cho thấy chúng có đặc trưng tương tự nhau hơn so với Setosa. Tuy nhiên, chúng vẫn có sự phân biệt tương đối rõ ràng.
- **Giảm chiều hiệu quả:**
 - Mặc dù bộ dữ liệu Iris ban đầu có 4 đặc trưng, hai thành phần chính của PCA (PC1 và PC2) đã giữ lại phần lớn phương sai trong dữ liệu, cho phép phân biệt ba loài hoa trong không gian 2D.
 - PCA không chỉ giảm chiều dữ liệu mà còn làm nổi bật các mối quan hệ tiềm ẩn giữa các đặc trưng và các cụm trong dữ liệu.

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT


4. DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

a. Cách hoạt động:

DBSCAN là một thuật toán phân cụm dựa trên mật độ, tìm các cụm bằng cách nhóm các điểm gần nhau và xác định các điểm nhiễu (outliers). DBSCAN không yêu cầu số lượng cụm phải được chỉ định trước.

b. Cách thực hiện:

1. Chọn một điểm dữ liệu.
2. Nếu có đủ điểm lân cận trong một bán kính nhất định, điểm đó là một phần của cụm.
3. Tiếp tục mở rộng cụm bằng cách lặp lại cho các điểm lân cận.
4. Những điểm không thuộc cụm nào được xem là điểm nhiễu.



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

c. Ưu điểm:

- Tự động tìm số cụm.
- Phát hiện tốt các điểm nhiễu.
- Hiệu quả với dữ liệu có hình dạng phức tạp.

d. Nhược điểm:

- Cần xác định tốt tham số bán kính ϵ và số điểm tối thiểu.

e. Ứng dụng:

- Phát hiện bất thường trong dữ liệu mạng.
- Nhóm các đối tượng có hình dạng bất thường.

f. Ví dụ trong Python:

DBSCAN


```
from sklearn.cluster import DBSCAN
from sklearn.datasets import make_moons
import matplotlib.pyplot as plt

# Tạo dữ liệu dạng hình trăng khuyết
X, _ = make_moons(n_samples=300, noise=0.05)

# Áp dụng DBSCAN
dbscan = DBSCAN(eps=0.1, min_samples=5)
clusters = dbscan.fit_predict(X)

# Hiển thị kết quả phân cụm
plt.scatter(X[:, 0], X[:, 1], c=clusters)
plt.title('DBSCAN Clustering')
plt.show()
```

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT



- **Cụm màu sắc khác nhau:** Mỗi cụm trong hình được phân biệt bằng một màu sắc khác nhau. DBSCAN đã xác định được 3 cụm chính, bao gồm các cụm hình dạng không đều:
 - Màu **tím** (phía trên bên trái) đại diện cho một cụm với hình dạng cong.
 - Màu **xanh lá cây** (bên phải) và **xanh dương** (bên dưới) là hai cụm khác.
 - **Điểm màu vàng và xanh lam nhạt:** Đây có thể là các điểm ở biên (border points), nghĩa là chúng thuộc cụm nhưng có ít điểm lân cận hơn so với các điểm trung tâm của cụm.
 - **Điểm màu tím đậm** (trên khắp hình): Những điểm này là các điểm nhiễu hoặc ngoại lai (noise points). Chúng không thuộc bất kỳ cụm nào do không đủ điểm lân cận hoặc ở quá xa các cụm chính.
-
- **DBSCAN** đã phân cụm thành công dữ liệu thành các cụm dựa trên mật độ, đồng thời phát hiện các điểm nhiễu và các điểm nằm trên biên của các cụm.
 - Thuật toán này rất phù hợp cho dữ liệu có hình dạng phức tạp, không theo dạng cụm hình cầu, điều mà các thuật toán như K-Means khó có thể làm được.

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT


5. t-SNE (t-Distributed Stochastic Neighbor Embedding)

a. Cách hoạt động:

t-SNE là một thuật toán giảm chiều dùng để trực quan hóa dữ liệu có nhiều chiều. Nó giảm số chiều xuống còn 2 hoặc 3 để có thể hiển thị trên đồ thị.

b. Cách thực hiện:

1. Chuyển đổi dữ liệu từ không gian nhiều chiều sang không gian 2 hoặc 3 chiều.
2. Tối ưu hóa để giữ các điểm gần nhau trong không gian thấp giống với quan hệ khoảng cách của chúng trong không gian ban đầu.



CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

c. Ưu điểm:

- Giảm chiều dữ liệu rất hiệu quả, giúp trực quan hóa dữ liệu phức tạp.
- Hiển thị tốt các cụm trong dữ liệu.

d. Nhược điểm:

- Tính toán phức tạp và chậm với dữ liệu lớn.
- Không bảo toàn khoảng cách tuyệt đối giữa các điểm.

e. Ứng dụng:

- Trực quan hóa dữ liệu lớn và phức tạp như dữ liệu gen, dữ liệu hình ảnh.

f. Ví dụ trong Python:

t_SNE

```
from sklearn.manifold import TSNE
from sklearn.datasets import load_iris
import matplotlib.pyplot as plt
import pandas as pd


# Tải bộ dữ liệu Iris
iris = load_iris()
X = iris.data
y = iris.target

# Áp dụng t-SNE để giảm chiều dữ liệu xuống 2 chiều
tsne = TSNE(n_components=2, random_state=42)
X_tsne = tsne.fit_transform(X)

# Tạo DataFrame để chứa kết quả
tsne_results = pd.DataFrame(X_tsne, columns=['TSNE1', 'TSNE2'])
tsne_results['Target'] = y

# Vẽ biểu đồ t-SNE
plt.figure(figsize=(8, 6))
plt.scatter(tsne_results['TSNE1'], tsne_results['TSNE2'], c=tsne_results['Target'], cmap='viridis')
plt.title('t-SNE on Iris Dataset')
plt.xlabel('TSNE1')
plt.ylabel('TSNE2')
plt.colorbar(label='Target')
plt.show()
```

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT



- **Trục X (TSNE1) và Trục Y (TSNE2):** Đây là hai thành phần chính sau khi t-SNE giảm chiều dữ liệu từ 4 chiều xuống 2 chiều. Các trục này không có ý nghĩa cụ thể như các đặc trưng ban đầu, mà chúng là các chiều mới do thuật toán t-SNE tạo ra, nhằm giữ lại cấu trúc của dữ liệu.
- **Màu sắc:** Màu sắc khác nhau trên biểu đồ đại diện cho các loài hoa khác nhau trong bộ dữ liệu Iris:
 - Màu **tím** (Target 0): Iris-setosa
 - Màu **xanh lam** (Target 1): Iris-versicolor
 - Màu **vàng** (Target 2): Iris-virginica
- **Cách phân tách các cụm:**
 - Các điểm màu **tím** (Iris-setosa) tách biệt rõ ràng khỏi các loài hoa khác, cho thấy Setosa có các đặc trưng rất khác biệt so với Versicolor và Virginica.
 - Các điểm màu **xanh lam** (Iris-versicolor) và **vàng** (Iris-virginica) có sự chồng lấn nhất định. Điều này phản ánh sự tương đồng về các đặc trưng của chúng trong dữ liệu gốc, đặc biệt là khi Iris-versicolor và Iris-virginica có một số đặc trưng khá giống nhau.

CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

Tóm tắt:

Đặc điểm	PCA	t-SNE
Mục tiêu	Bảo toàn cấu trúc toàn cục	Bảo toàn cấu trúc cục bộ
Loại giảm chiều	Tuyến tính	Phi tuyến
Tốc độ	Nhanh hơn	Chậm hơn
Cấu trúc bảo toàn	Toàn cục	Cục bộ
Số chiều giảm	Bất kỳ (thường dùng 2, 3 hoặc nhiều hơn)	Thường là 2 hoặc 3
Diễn giải	Dễ diễn giải	Khó diễn giải
Ứng dụng	Giảm chiều trước học máy	Trực quan hóa dữ liệu

ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

1. Phương pháp đánh giá nội bộ (Internal Evaluation)

Phương pháp đánh giá nội bộ chỉ dựa trên dữ liệu đầu vào và cấu trúc của các cụm được phát hiện. Các tiêu chí này đo lường sự liên kết của các điểm dữ liệu trong một cụm và sự khác biệt giữa các cụm.


a. Silhouette Score (Chỉ số Silhouette)

- **Cách hoạt động:** Silhouette Score đo lường mức độ gắn kết của các điểm trong cụm của chúng và mức độ khác biệt của chúng so với các cụm khác.

- **Silhouette coefficient** cho từng điểm i được tính bằng:

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$ là khoảng cách trung bình từ điểm i đến tất cả các điểm trong cùng cụm.
- $b(i)$ là khoảng cách trung bình từ điểm i đến tất cả các điểm trong cụm gần nhất.
- Giá trị của Silhouette Score nằm trong khoảng từ -1 đến 1:
 - 1: Điểm nằm trong cụm đúng với sự phân tách tốt.
 - 0: Điểm ở ranh giới giữa các cụm.
 - -1: Điểm có thể bị phân vào cụm sai.



ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

b. Davies-Bouldin Index

- Cách hoạt động: Chỉ số Davies-Bouldin đo lường mức độ "gắn kết" và "tách biệt" giữa các cụm. Nó sử dụng tỷ số giữa khoảng cách trong cụm và khoảng cách giữa các cụm:

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{i \neq j} \left(\frac{d_i + d_j}{d_{ij}} \right)$$

- d_i là khoảng cách trung bình giữa các điểm trong cụm i .
- d_{ij} là khoảng cách giữa tâm cụm i và cụm j .

Giá trị thấp hơn của chỉ số Davies-Bouldin cho thấy các cụm được hình thành tốt hơn.

ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

c. Dunn Index

- **Cách hoạt động:** Chỉ số Dunn đo lường tỷ lệ giữa khoảng cách nhỏ nhất giữa hai cụm khác nhau và đường kính lớn nhất của bất kỳ cụm nào:

$$DI = \frac{\min_{i \neq j} d(C_i, C_j)}{\max_k \delta(C_k)}$$

- $d(C_i, C_j)$ là khoảng cách giữa hai cụm C_i và C_j .
- $\delta(C_k)$ là đường kính lớn nhất của cụm C_k .

Giá trị **Dunn Index** cao hơn biểu thị sự phân tách tốt hơn giữa các cụm.

ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

2. Phương pháp đánh giá bên ngoài (External Evaluation)

Phương pháp đánh giá bên ngoài yêu cầu biết trước các nhãn thực của dữ liệu (ground truth) để so sánh với kết quả phân cụm được tạo ra. Đây là cách đánh giá dựa trên việc kiểm tra sự tương đồng giữa các cụm và nhãn thực.

a. Rand Index

- **Cách hoạt động:** Rand Index đo lường mức độ tương đồng giữa các cụm và các nhãn thực, tính tỷ lệ của cặp điểm được phân loại đúng. Cụ thể, nó so sánh số lượng cặp điểm được gán đúng vào cùng một cụm (hoặc khác cụm) với tổng số cặp điểm có thể có.

$$RI = \frac{TP + TN}{TP + TN + FP + FN}$$

- **TP** (True Positive) và **TN** (True Negative) là các cặp điểm được phân đúng cụm.
- **FP** (False Positive) và **FN** (False Negative) là các cặp bị phân sai cụm.

Giá trị của Rand Index nằm trong khoảng từ 0 đến 1, với 1 là phân cụm hoàn hảo.

ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

b. Adjusted Rand Index (ARI)

- **Cách hoạt động:** Adjusted Rand Index (ARI) điều chỉnh Rand Index để loại bỏ khả năng phân cụm ngẫu nhiên. ARI điều chỉnh dựa trên kỳ vọng của Rand Index khi phân cụm ngẫu nhiên. Giá trị của ARI nằm trong khoảng từ -1 đến 1:
 - 1: Phân cụm hoàn hảo.
 - 0: Phân cụm ngẫu nhiên.
 - < 0: Kết quả phân cụm tệ hơn cả ngẫu nhiên.

c. Mutual Information (MI)

- **Cách hoạt động:** Mutual Information đo lường mức độ thông tin chung giữa nhãn phân cụm và nhãn thực, dựa trên lý thuyết thông tin. Một phiên bản điều chỉnh, **Adjusted Mutual Information (AMI)**, tính toán sự chênh lệch so với phân cụm ngẫu nhiên.
- **Ưu điểm:** Cân bằng tốt giữa phân cụm ngẫu nhiên và các cụm thực.

ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

VÍ DỤ

1. Bộ dữ liệu Iris

Bộ dữ liệu Iris có 150 mẫu với 4 đặc trưng và 3 nhãn lớp (loài hoa). Tuy nhiên, trong học không giám sát, chúng ta chỉ sử dụng các đặc trưng để phân cụm mà không sử dụng nhãn lớp trong quá trình huấn luyện mô hình.

2. Phân cụm với K-Means và DBSCAN

- K-Means là một thuật toán phân cụm dựa trên centroid (tâm cụm).
- DBSCAN là một thuật toán phân cụm dựa trên mật độ.

ĐÁNH GIÁ CÁC THUẬT TOÁN HỌC MÁY KHÔNG GIÁM SÁT

=== Đánh giá K-Means ===

Silhouette Score: 0.46

Davies-Bouldin Index: 0.83

Adjusted Rand Index (External): 0.62

Dunn Index: 0.03

=== Đánh giá DBSCAN ===

Silhouette Score: 0.36

Davies-Bouldin Index: 7.12

Adjusted Rand Index (External): 0.44

Dunn Index: 0.05

K-Means:


- **Silhouette Score (0.46):** Cho thấy các cụm của K-Means có mức độ gắn kết khá, không quá tách biệt nhưng vẫn tương đối tốt.
- **Davies-Bouldin Index (0.83):** Chỉ số thấp, biểu thị các cụm của K-Means có sự tách biệt tốt và độ gắn kết cao.
- **Adjusted Rand Index (0.62):** Mức độ tương đồng tương đối cao với nhãn thực, chứng tỏ K-Means phân loại gần đúng với cấu trúc thực của dữ liệu Iris.
- **Dunn Index (0.03):** Chỉ số Dunn thấp, cho thấy khoảng cách giữa các cụm không lớn so với độ chênh lệch trong cụm, nghĩa là sự tách biệt giữa các cụm không hoàn toàn tốt.

DBSCAN:

- **Silhouette Score (0.36):** Cho thấy các cụm của DBSCAN kém tách biệt hơn so với K-Means, mức độ gắn kết giữa các cụm thấp.
- **Davies-Bouldin Index (7.12):** Giá trị rất cao, cho thấy sự phân tách của DBSCAN không tốt, cụm bị chồng lấn nhiều và có sự lộn xộn trong dữ liệu.
- **Adjusted Rand Index (0.44):** Thấp hơn so với K-Means, chứng tỏ DBSCAN không tương thích với cấu trúc thực của dữ liệu Iris.
- **Dunn Index (0.05):** Cao hơn K-Means nhưng vẫn thấp, biểu thị sự phân cụm không tốt, khoảng cách giữa các cụm không lớn.

CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG

Học tăng cường (**Reinforcement Learning - RL**) là một lĩnh vực trong học máy, nơi một **tác nhân (agent)** học cách hành động trong một môi trường để tối đa hóa phần thưởng tích lũy theo thời gian. Trong học tăng cường, tác nhân tương tác với môi trường, quan sát trạng thái, thực hiện hành động, nhận phản hồi dưới dạng phần thưởng, và điều chỉnh chiến lược của mình để cải thiện hiệu suất trong dài hạn.



CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG

1. Q-Learning

a. Cách hoạt động:

- **Q-Learning** là một thuật toán học tăng cường dựa trên bảng (table-based) không mô hình, nơi tác nhân học một hàm giá trị hành động $Q(s, a)$ để ước tính giá trị của việc thực hiện hành động a trong trạng thái s . Sau đó, tác nhân sẽ chọn hành động tốt nhất dựa trên giá trị $Q(s, a)$ lớn nhất.
- Công thức cập nhật của **Q-Learning**:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- α : Tốc độ học.
- γ : Yếu tố chiết khấu, quyết định tầm quan trọng của phần thưởng tương lai.
- r : Phần thưởng nhận được sau khi thực hiện hành động a ở trạng thái s .
- s' : Trạng thái mới sau khi thực hiện hành động a .

- Đơn giản, dễ thực hiện.
- Không yêu cầu mô hình của môi trường.

- Không mở rộng tốt cho không gian trạng thái lớn vì yêu cầu bảng Q lưu trữ cho mọi trạng thái và hành động.



		Action						
		0	1	2	3	4	5	6
R =	0	-1	0	-1	-1	-1	-1	-1
	1	0	-1	0	0	-1	-1	-1
	2	-1	-1	-1	-1	0	-1	-1
	3	-1	0	-1	-1	-1	0	100
	4	-1	-1	0	-1	-1	-1	-1
	5	-1	-1	-1	0	-1	-1	-1
	6	-1	-1	-1	0	-1	-1	100
State								


CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG

Ví dụ về cách triển khai thuật toán **Q-Learning** trong môi trường **Gridworld** (một dạng bài toán chơi cờ hoặc di chuyển trên lưới). Trong bài toán này, tác nhân (agent) di chuyển trên lưới với mục tiêu đến được vị trí đích và nhận phần thưởng, đồng thời tránh các vị trí "bẫy" gây mất điểm.

1. Bài toán mô phỏng môi trường Gridworld

- **Môi trường:** Một lưới 4x4.
- **Mục tiêu:** Tác nhân di chuyển từ một vị trí ban đầu đến đích (goal) và nhận phần thưởng.
- **Trạng thái (State):** Mỗi ô trên lưới là một trạng thái.
- **Hành động (Action):** Tác nhân có thể di chuyển **trái, phải, lên, xuống**.
- **Phần thưởng (Reward):** Phần thưởng +1 khi đến được đích, và phần thưởng -1 khi rơi vào bẫy.

CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG




1. Các ô có màu sáng hơn:

- Các ô ở hàng 0 (ở phía trên) có giá trị cao hơn so với các ô ở phía dưới. Điều này cho thấy rằng các trạng thái này có giá trị Q lớn hơn, tức là chúng nằm gần mục tiêu hơn (ô đích). Ví dụ, tại vị trí (0,3), giá trị trạng thái là **0.8**, đây là trạng thái gần mục tiêu, nên nó có giá trị cao vì tác nhân học được rằng di chuyển về phía mục tiêu sẽ mang lại phần thưởng tích cực.

2. Các ô có màu xanh lam (giá trị thấp nhất):

- Ô tại vị trí (1,1) có giá trị gần bằng **0** và có màu xanh lam đậm, biểu thị một trạng thái có giá trị rất thấp. Đây là ô bẫy (trap), nơi tác nhân bị phạt nếu đi vào. Vì tác nhân học được rằng đi vào trạng thái này sẽ nhận phần thưởng tiêu cực (-1), nên giá trị của nó rất thấp.

CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG



3. Các ô ở hàng dưới có giá trị thấp hơn:

- Các ô ở các hàng dưới (hàng 2 và 3) có giá trị thấp hơn so với hàng 0. Điều này có thể là vì các trạng thái này nằm xa hơn khỏi mục tiêu hoặc ở các trạng thái này, các hành động tốt nhất không trực tiếp dẫn đến đích. Ví dụ, giá trị trạng thái ở (3,2) là **0.3**, thấp hơn nhiều so với các trạng thái ở hàng 0.


4. Hướng di chuyển tốt:

- Giá trị tăng dần từ các trạng thái ở góc dưới bên trái đến góc trên bên phải cho thấy hướng di chuyển tối ưu của tác nhân là từ các trạng thái phía dưới và di chuyển theo hướng phải và lên (trên đồ thị) để đạt được mục tiêu.

5. Phần thưởng:

- Tác nhân học được rằng di chuyển về phía ô đích (vị trí 3,3, không được biểu diễn trong đồ thị trực tiếp nhưng có phần thưởng cao) sẽ mang lại phần thưởng cao, trong khi di chuyển về phía ô bẫy (1,1) sẽ bị phạt, điều này phản ánh qua giá trị thấp của ô này.

CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG



Testing the Q-Learning Model:

Starting at position (0, 0)

Step 1: Move down to position (1, 0)

Step 2: Move down to position (2, 0)

Step 3: Move right to position (2, 1)

Step 4: Move down to position (3, 1)

Step 5: Move right to position (3, 2)

Step 6: Move right to position (3, 3)

Reached the goal at position (3, 3) in 6 steps!

Trong kết quả này, tác nhân đã di chuyển từ (0, 0) đến đích (3, 3) mà không rơi vào bẫy.

CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG

2. Deep Q-Network (DQN)

a. Cách hoạt động:

- Deep Q-Network là phiên bản mở rộng của Q-Learning, sử dụng **mạng nơ-ron sâu (Deep Neural Network)** để xấp xỉ hàm $Q(s, a)$ thay vì lưu trữ bảng Q. DQN được sử dụng để giải quyết các bài toán phức tạp với không gian trạng thái và hành động lớn.
- DQN sử dụng **replay buffer** (bộ nhớ đệm) để lưu trữ các trải nghiệm trong quá khứ và **mục tiêu kép (double Q-learning)** để ngăn chặn vấn đề cập nhật không ổn định.

b. Ưu điểm:

- Khả năng mở rộng tốt hơn so với Q-Learning nhờ việc sử dụng mạng nơ-ron để xấp xỉ hàm giá trị.

c. Nhược điểm:

- Huấn luyện phức tạp và có thể không ổn định nếu không điều chỉnh tốt các tham số.

CÁC THUẬT TOÁN HỌC MÁY TĂNG CƯỜNG

3. SARSA (State-Action-Reward-State-Action)

a. Cách hoạt động:

- SARSA là một thuật toán học tăng cường khác cũng sử dụng bảng Q, nhưng khác với Q-Learning, nó cập nhật hàm giá trị dựa trên hành động mà tác nhân thực sự thực hiện, không dựa trên hành động tối ưu lý thuyết.
- Công thức cập nhật của SARSA:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

- s' là trạng thái mới, và a' là hành động thực sự đã được chọn sau đó.

b. Ưu điểm:

- Thích hợp cho các môi trường có chính sách mềm dẻo hơn và nơi tác nhân không luôn tìm cách tối ưu hóa hành động ngay lập tức.

c. Nhược điểm:

- Có thể chậm trong việc hội tụ đến giải pháp tối ưu so với Q-Learning, vì nó chỉ cập nhật dựa trên hành động đã thực hiện thay vì hành động tốt nhất.

3.4. Ứng dụng học máy



3.4. Ứng dụng học máy

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Khoa học

a. Dự đoán thời tiết

- **Ý nghĩa:** Dự báo thời tiết là một trong những ứng dụng quan trọng của học máy, nơi mô hình học máy được sử dụng để dự đoán các yếu tố thời tiết dựa trên lượng dữ liệu khổng lồ từ các nguồn khác nhau như vệ tinh, radar, và cảm biến.
- **Phương pháp:** Các mô hình hồi quy và mạng nơ-ron sâu (Deep Learning) được sử dụng để phân tích dữ liệu thời tiết và đưa ra các dự đoán chính xác hơn.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Khoa học

a. Dự đoán thời tiết

- **Ứng dụng thực tiễn:** IBM Watson sử dụng trí tuệ nhân tạo và học máy để phân tích dữ liệu thời tiết toàn cầu, bao gồm dữ liệu từ vệ tinh, radar và các thiết bị đo đạc, để dự đoán thời tiết với độ chính xác cao.
- **Tính năng:** Dự đoán thời tiết theo thời gian thực, cảnh báo về thiên tai và các sự kiện thời tiết cực đoan.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Khoa học

b. Phát hiện gian lận

- Ý nghĩa: Phát hiện gian lận trong các hệ thống tài chính và giao dịch trực tuyến là một lĩnh vực quan trọng, đặc biệt trong các hệ thống thanh toán và ngân hàng.
- Phương pháp: Các mô hình học máy như phân loại (classification) và phát hiện bất thường (anomaly detection) được sử dụng để phát hiện các giao dịch gian lận dựa trên các mẫu dữ liệu bất thường trong các giao dịch trước đó.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Khoa học

b. Phát hiện gian lận

- Ứng dụng thực tiễn: PayPal sử dụng các mô hình học máy để phát hiện gian lận trong thời gian thực khi người dùng thực hiện các giao dịch trực tuyến. Hệ thống phân tích dữ liệu giao dịch để phát hiện các mẫu bất thường và ngăn chặn hành vi gian lận.
- Tính năng: Phân tích và đánh giá các giao dịch theo thời gian thực, đưa ra cảnh báo khi phát hiện giao dịch bất thường.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Khoa học

c. Phân tích tài chính

- Ý nghĩa: Phân tích tài chính bao gồm việc dự đoán xu hướng thị trường, quản lý rủi ro và tối ưu hóa danh mục đầu tư.
- Phương pháp: Các thuật toán học máy như cây quyết định (decision tree) và mạng nơ-ron hồi quy (recurrent neural network) thường được sử dụng để xử lý các dữ liệu tài chính và dự đoán xu hướng của thị trường.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Khoa học

c. Phân tích tài chính

- Ứng dụng thực tiễn: Bloomberg Terminal sử dụng học máy để cung cấp các phân tích tài chính phức tạp, dự đoán xu hướng thị trường và giúp các nhà đầu tư đưa ra quyết định. Bằng cách sử dụng các thuật toán học máy như hồi quy và mạng nơ-ron, Bloomberg có thể phân tích dữ liệu lịch sử và phát hiện các cơ hội đầu tư tiềm năng.
- Tính năng:
 - Dự đoán giá cổ phiếu và các tài sản tài chính khác.
 - Phân tích biến động của thị trường tài chính theo thời gian thực, cung cấp các khuyến nghị đầu tư.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kỹ thuật

a. Xe tự lái

- Ý nghĩa: Xe tự lái là một trong những ứng dụng kỹ thuật đáng chú ý nhất của học máy. Hệ thống này dựa vào dữ liệu từ cảm biến, camera và radar để nhận diện môi trường xung quanh và đưa ra quyết định di chuyển.
- Phương pháp: Các mô hình học tăng cường (Reinforcement Learning), cùng với thị giác máy tính (Computer Vision), giúp xe tự học cách lái an toàn và tối ưu hóa hành vi di chuyển trên đường.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kỹ thuật

a. Xe tự lái

- Ứng dụng thực tiễn: Tesla là một trong những công ty tiên phong trong việc phát triển xe tự lái. Xe Tesla sử dụng hệ thống AI và học tăng cường (Reinforcement Learning) để học cách điều khiển xe, nhận diện môi trường xung quanh và tự động lái trong các điều kiện khác nhau.
- Tính năng: Nhận diện người đi bộ, phương tiện giao thông, biển báo, và điều hướng xe trên đường cao tốc hoặc đường đô thị.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kỹ thuật

b. Nhận dạng giọng nói

- Ý nghĩa: Nhận dạng giọng nói được sử dụng trong các hệ thống trợ lý ảo như Siri, Google Assistant, giúp chuyển đổi âm thanh thành văn bản và hiểu ý nghĩa của chúng.
- Phương pháp: Các thuật toán học sâu (Deep Learning), đặc biệt là mạng nơ-ron hồi quy LSTM và CNN, được sử dụng để phân tích và hiểu ngữ cảnh của giọng nói.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kỹ thuật

b. Nhận dạng giọng nói

- Ứng dụng thực tiễn: Google Assistant sử dụng học máy để nhận diện giọng nói và hiểu các câu lệnh của người dùng. Hệ thống học sâu này giúp chuyển đổi giọng nói thành văn bản, sau đó phân tích và thực hiện các yêu cầu của người dùng.
- Tính năng: Điều khiển thiết bị, tìm kiếm thông tin, nhắn tin, gọi điện, điều khiển ngôi nhà thông minh bằng giọng nói.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kỹ thuật

c. Thị giác máy tính (Computer Vision)

- Ý nghĩa: Thị giác máy tính là lĩnh vực nghiên cứu và phát triển các hệ thống có khả năng "nhìn" và hiểu hình ảnh. Ứng dụng này phổ biến trong các hệ thống nhận dạng khuôn mặt, phân tích ảnh y khoa, và robot tự động.
- Phương pháp: Mạng nơ-ron tích chập (Convolutional Neural Networks - CNN) là một kỹ thuật phổ biến để xử lý và phân tích hình ảnh.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kỹ thuật

c. Thị giác máy tính (Computer Vision)

- Ứng dụng thực tiễn: Trong ngành sản xuất, các hệ thống thị giác máy tính sử dụng học máy để kiểm tra chất lượng sản phẩm, phát hiện các lỗi nhỏ nhất trong sản xuất như lỗi in, hỏng hóc, hoặc sản phẩm không đạt tiêu chuẩn.
- Tính năng: Phát hiện các lỗi trên bề mặt sản phẩm, đo đạc kích thước chính xác, kiểm tra các sản phẩm một cách tự động.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kinh doanh

a. Tiếp thị mục tiêu

- Ý nghĩa: Học máy được sử dụng để tạo ra các chiến lược tiếp thị được cá nhân hóa, giúp các doanh nghiệp gửi thông điệp đến đúng khách hàng mục tiêu.
- Phương pháp: Các thuật toán phân loại và phân cụm (clustering) giúp phân tích hành vi người dùng và xác định các nhóm khách hàng tiềm năng cho các chiến dịch tiếp thị.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kinh doanh

a. Tiếp thị mục tiêu

- Ứng dụng thực tiễn: Facebook Ads sử dụng học máy để phân tích hành vi người dùng và tối ưu hóa việc quảng cáo cho các đối tượng cụ thể. Facebook Ads dựa trên các dữ liệu về tương tác, sở thích, lịch sử duyệt web của người dùng để cung cấp các quảng cáo phù hợp.
- Tính năng: Cá nhân hóa quảng cáo, tối ưu hóa chi phí quảng cáo, nhắm mục tiêu chính xác hơn đến các nhóm khách hàng.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kinh doanh

b. Phân tích khách hàng

- Ý nghĩa: Phân tích hành vi và nhu cầu của khách hàng giúp các doanh nghiệp hiểu rõ hơn về thị trường và cải thiện chiến lược kinh doanh.
- Phương pháp: Các thuật toán phân cụm như K-Means, PCA được sử dụng để phân tích và nhóm các khách hàng theo hành vi mua sắm hoặc các đặc điểm khác.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kinh doanh

b. Phân tích khách hàng

- Ứng dụng thực tiễn: Amazon sử dụng học máy để phân tích hành vi mua sắm của người dùng và phân nhóm khách hàng dựa trên các đặc điểm như lịch sử mua sắm, sở thích và phản hồi sản phẩm.
- Tính năng: Đề xuất sản phẩm, phân nhóm khách hàng, phân tích và dự đoán nhu cầu tiêu dùng.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kinh doanh

c. Đề xuất sản phẩm

- Ý nghĩa: Hệ thống đề xuất sản phẩm giúp cung cấp cho người dùng các sản phẩm hoặc dịch vụ dựa trên sở thích và hành vi của họ.
- Phương pháp: Các hệ thống khuyến nghị (Recommendation Systems) thường dựa trên mô hình cộng tác (collaborative filtering) và mạng nơ-ron để đề xuất sản phẩm phù hợp với khách hàng.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Kinh doanh

c. Đề xuất sản phẩm

- Ứng dụng thực tiễn: Netflix sử dụng học máy để cá nhân hóa nội dung cho từng người dùng. Hệ thống này dựa trên lịch sử xem, đánh giá, và sở thích của người dùng để đề xuất các bộ phim, chương trình truyền hình có liên quan.
- Tính năng: Đề xuất phim và chương trình TV phù hợp với sở thích cá nhân, tăng trải nghiệm người dùng.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

a. Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP)

- Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) Ý nghĩa: Học máy giúp phát triển các hệ thống hiểu và phản hồi ngôn ngữ con người, như chatbot, dịch máy, hoặc các ứng dụng hỗ trợ văn bản.
- Phương pháp: Các mô hình ngôn ngữ dựa trên học sâu như GPT và BERT đang được sử dụng rộng rãi để hiểu và tạo ra ngôn ngữ tự nhiên với độ chính xác cao.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

a. Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP)

- Ứng dụng thực tiễn: GPT-4, phát triển bởi OpenAI, là một trong những mô hình xử lý ngôn ngữ tự nhiên tiên tiến nhất. Nó có khả năng hiểu và tạo ra ngôn ngữ tự nhiên, giúp xây dựng các chatbot và hệ thống tự động trả lời, hỗ trợ dịch thuật, và cung cấp thông tin.
- Tính năng: Hiểu ngôn ngữ tự nhiên, tạo ra các câu trả lời tương tác, giúp dịch ngôn ngữ và xử lý văn bản tự động.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

a. Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP)

- Ứng dụng thực tiễn: GPT-4, phát triển bởi OpenAI, là một trong những mô hình xử lý ngôn ngữ tự nhiên tiên tiến nhất. Nó có khả năng hiểu và tạo ra ngôn ngữ tự nhiên, giúp xây dựng các chatbot và hệ thống tự động trả lời, hỗ trợ dịch thuật, và cung cấp thông tin.
- Tính năng: Hiểu ngôn ngữ tự nhiên, tạo ra các câu trả lời tương tác, giúp dịch ngôn ngữ và xử lý văn bản tự động.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

b. Y học

- Ý nghĩa: Học máy đã được áp dụng trong nhiều lĩnh vực y tế như chẩn đoán bệnh, dự đoán kết quả điều trị, và phát hiện sớm bệnh lý thông qua phân tích dữ liệu y khoa.
- Phương pháp: Mạng nơ-ron tích chập (CNN) và các mô hình học sâu khác được sử dụng để phân tích ảnh y khoa (chẳng hạn như X-quang, MRI) để phát hiện bệnh ung thư và các bệnh lý khác.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

b. Y học

- Ứng dụng thực tiễn: IBM Watson for Oncology sử dụng học máy để phân tích dữ liệu bệnh nhân và cung cấp các khuyến nghị về phác đồ điều trị. Watson có thể phân tích các triệu chứng, dữ liệu y khoa và tài liệu để giúp bác sĩ đưa ra quyết định tốt hơn trong việc điều trị bệnh nhân ung thư.
- Tính năng: Phân tích hồ sơ y tế bệnh nhân, đề xuất các phác đồ điều trị phù hợp dựa trên các tài liệu y khoa.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

c. Giáo dục

- Ý nghĩa: Học máy được sử dụng để cá nhân hóa quá trình học tập, giúp tạo ra các lộ trình học phù hợp với từng học viên, đánh giá hiệu suất và cung cấp phản hồi tức thì.
- Phương pháp: Các hệ thống học tập thông minh (Intelligent Tutoring Systems) sử dụng mô hình học máy để theo dõi và điều chỉnh quá trình học tập của học viên theo thời gian thực.

ỨNG DỤNG CỦA HỌC MÁY

Ứng dụng trong Lĩnh vực Xã hội

c. Giáo dục

- Ứng dụng thực tiễn: Coursera sử dụng học máy để phân tích hành vi học tập của sinh viên và đưa ra các đề xuất về khóa học, bài giảng và các lộ trình học tập phù hợp với khả năng của từng cá nhân.
- Tính năng: Cá nhân hóa lộ trình học tập, theo dõi tiến độ và đề xuất nội dung học tập phù hợp với từng sinh viên.